



UNIVERSITÀ DI PISA

DIPARTIMENTO DI MATEMATICA

Laurea Triennale in Matematica

Mixing times di catene di Markov

Relatore:

Prof. Alessandra Caraceni

Candidato:

Giordano Sorrentino

ANNO ACCADEMICO 2025/2026

Indice

Introduzione	3
1 Nozioni preliminari	4
1.1 Catene di Markov	4
1.2 Passeggiate aleatorie su gruppi	8
1.3 Speranza condizionale	9
1.4 Norma ℓ^p	10
2 Introduzione al mixing	11
2.1 Distanza dalla stazionarietà e mixing time	11
2.2 Distanza in variazione totale e coupling	12
2.3 Distanza $\bar{d}$ e submoltiplicatività	15
3 Tecniche	18
3.1 Coupling	18
3.1.1 Coupling di catene	18
3.1.2 Grand coupling e cammini su reticoli	21
3.2 Strong Stationary Times	23
3.2.1 Tempi di arresto	24
3.2.2 Stationary Times	24
3.2.3 Strong Stationary Times	25
3.2.4 Esempi di applicazione	27
3.3 Metodi spettrali	33
3.3.1 Autovalori	34
3.3.2 Il relaxation time	35
3.3.3 Stima in ℓ^2	41
3.3.4 Il metodo di Wilson per le stime dal basso	44
4 Fenomeno del cutoff	46
4.1 Definizione del cutoff	46
4.2 Esempi	47

5	Trasposizioni aleatorie	49
5.1	Introduzione al problema	49
5.2	Costruzione di Broder	50
5.3	Costruzione di Matthews	54
5.3.1	Prima parte dell'algoritmo	55
5.3.2	Seconda parte dell'algoritmo	59
5.3.3	L'errore nella costruzione di Matthews	60
5.3.4	Risultati	61
5.4	Profilo limite	64
6	Trasposizioni adiacenti	65
6.1	Introduzione al problema	65
6.2	Stima dal basso	66
6.3	Cammini sui reticoli e autofunzione	68
6.4	Stima dall'alto	70

Introduzione

Il punto di partenza di questa tesi è il comportamento delle catene di Markov per tempi lunghi. Quando lo spazio degli stati è finito e la catena è irriducibile e aperiodica, la distribuzione della catena converge a un'unica distribuzione stazionaria. Il problema del mixing consiste nel rendere quantitativa questa convergenza: vogliamo capire quanto tempo deve passare affinché la distribuzione della catena sia vicina a quella stazionaria. Nel caso del mescolamento di un mazzo di carte, ad esempio, la domanda diventa quante mosse siano necessarie affinché il mazzo possa essere considerato approssimativamente mischiato.

Per rispondere a questa domanda si misura la distanza in variazione totale tra la distribuzione stazionaria e la distribuzione della catena al tempo t quando parte dal peggior stato possibile. Il mixing time è il primo istante in cui questa distanza diventa piccola.

Lo studio del mixing si è sviluppato soprattutto dagli anni Ottanta, con i lavori di Diaconis e Shahshahani sulle trasposizioni aleatorie e di Aldous sulle passeggiate aleatorie su gruppi finiti [DS81, Ald83]. La teoria del mixing è ancora oggi un ambito di ricerca attivo, per via delle sue applicazioni agli algoritmi randomizzati e per i suoi legami con la fisica statistica e la combinatoria.

I primi due capitoli della tesi sono dedicati alle nozioni preliminari: richiamiamo le proprietà fondamentali delle catene di Markov a stati finiti, introduciamo le passeggiate aleatorie su gruppi e definiamo la distanza dalla stazionarietà.

A partire dal Capitolo 3 presentiamo tre tecniche fondamentali per stimare il mixing time. La prima è il coupling, in cui si costruiscono due copie della stessa catena e si cerca di farle incontrare rapidamente. La seconda è il metodo degli strong stationary times, che permette di ottenere stime dall'alto tramite tempi aleatori in cui la catena ha già distribuzione stazionaria. La terza è costituita dai metodi spettrali, che collegano il mixing time agli autovalori e alle autofunzioni della matrice di transizione.

Nel Capitolo 4 studiamo il fenomeno del cutoff, che descrive una transizione brusca dall'assenza di mescolamento all'equilibrio per successioni di catene di Markov. Infine applichiamo le tecniche introdotte a due problemi centrali della teoria del mixing. Nel Capitolo 5 analizziamo la catena delle trasposizioni aleatorie tramite strong stationary times; nel Capitolo 6 studiamo invece le trasposizioni adiacenti, usando il metodo di Wilson per la stima dal basso e una riduzione ai cammini sui reticoli per la stima dall'alto.

Capitolo 1

Nozioni preliminari

1.1 Catene di Markov

Per le nozioni generali sulle catene di Markov seguiremo principalmente [LP17, Capitoli 1–4].

Una **catena di Markov** è un processo aleatorio che si muove tra gli elementi di un insieme $\mathcal{X}$ nel seguente modo: quando ci si trova in $x \in \mathcal{X}$, la posizione successiva è scelta in base a una distribuzione di probabilità che dipende solo da x . Più precisamente, introduciamo la seguente definizione.

Definizione 1.1.1. Sia $\mathcal{X}$ un insieme finito o numerabile. Sia ν_0 una distribuzione di probabilità su $\mathcal{X}$ e sia $P : \mathcal{X} \times \mathcal{X} \rightarrow [0, 1]$ una matrice tale che, per ogni $x \in \mathcal{X}$, si abbia

$$\sum_{y \in \mathcal{X}} P(x, y) = 1.$$

Una *catena di Markov a tempi discreti con distribuzione iniziale ν_0 e matrice di transizione P* è una successione di variabili aleatorie $(X_t)_{t \in \mathbb{N}}$ a valori in $\mathcal{X}$ tale che

$$\mathbf{P}(X_0 = x) = \nu_0(x) \quad \text{per ogni } x \in \mathcal{X},$$

e tale che soddisfi la *proprietà di Markov*: per ogni intero non negativo t e per ogni $x_0, \dots, x_{t+1} \in \mathcal{X}$ tali che $\mathbf{P}(X_0 = x_0, \dots, X_t = x_t) > 0$, vale

$$\mathbf{P}(X_{t+1} = x_{t+1} \mid X_t = x_t, \dots, X_0 = x_0) = \mathbf{P}(X_{t+1} = x_{t+1} \mid X_t = x_t) = P(x_t, x_{t+1}).$$

L'insieme $\mathcal{X}$ è detto *spazio degli stati*. In questo elaborato analizzeremo solo catene di Markov a stati finiti, ovvero catene in cui l'insieme $\mathcal{X}$ è finito. Intenderemo inoltre che tali insiemi sono sempre accompagnati dall'insieme delle parti come σ -algebra.

Mostriamo che la distribuzione iniziale ν_0 e la matrice di transizione P determinano la distribuzione della catena al tempo t . Denotiamo con ν_t il vettore riga associato alla distribuzione della variabile aleatoria X_t :

$$\nu_t(x) = \mathbf{P}\{X_t = x\} \quad \text{per ogni } x \in \mathcal{X}.$$

Condizionando rispetto allo stato della catena al tempo t , otteniamo

$$(1.1.1) \quad \nu_{t+1}(y) = \sum_{x \in \mathcal{X}} \mathbf{P}\{X_t = x\} P(x, y) = \sum_{x \in \mathcal{X}} \nu_t(x) P(x, y) \quad \text{per ogni } y \in \mathcal{X}.$$

In forma matriciale diventa

$$\nu_{t+1} = \nu_t P \quad \text{per } t \geq 0,$$

da cui

$$(1.1.2) \quad \nu_t = \nu_0 P^t \quad \text{per } t \geq 0.$$

Spesso la distribuzione iniziale sarà concentrata in un singolo stato x . Chiamiamo questa distribuzione δ_x :

$$\delta_x(y) = \begin{cases} 1 & \text{se } y = x, \\ 0 & \text{se } y \neq x. \end{cases}$$

Introduciamo le notazioni $\mathbf{P}_x$ e $\mathbf{E}_x$ per indicare rispettivamente la probabilità e il valore atteso quando la catena ha distribuzione iniziale δ_x , ovvero quando parte dallo stato x . L'Equazione (1.1.2) implica che

$$\mathbf{P}_x(X_t = y) = (\delta_x P^t)(y) = P^t(x, y),$$

ovvero la probabilità di andare da x a y in t passi è data dall'entrata (x, y) di P^t . Per $x \in \mathcal{X}$, la riga di P indicizzata da x verrà denotata con $P(x, \cdot)$, che per quanto detto corrisponde alla distribuzione di probabilità $\mathbf{P}_x(X_1 = \cdot)$.

L'obiettivo principale di questo elaborato è studiare il comportamento delle catene di Markov per tempi lunghi. Le prossime due definizioni che introduciamo sono due semplici ma fondamentali proprietà delle catene di Markov che, come vedremo nel Teorema 1.1.6, sono sufficienti affinché la distribuzione di (X_t) converga per $t \rightarrow \infty$.

Una matrice di transizione P su $\mathcal{X}$ è detta **irriducibile** se per ogni coppia di stati $x, y \in \mathcal{X}$ esiste un intero non negativo t tale che $P^t(x, y) > 0$. Questo vuol dire che, partendo da qualsiasi stato, ogni altro stato viene raggiunto con probabilità positiva.

Sia $\mathcal{T}(x) := \{t \geq 1 : P^t(x, x) > 0\}$ l'insieme dei tempi per i quali è possibile che la catena torni nella posizione di partenza x . Il *periodo* di uno stato x è il massimo comun divisore degli elementi di $\mathcal{T}(x)$. Si verifica facilmente che se P è irriducibile, allora $\text{mcd } \mathcal{T}(x) = \text{mcd } \mathcal{T}(y)$ per ogni $x, y \in \mathcal{X}$.

Per una catena irriducibile, il periodo della catena è definito come il periodo comune di tutti gli stati. La catena è detta **aperiodica** se tutti gli stati hanno periodo 1, e **periodica** altrimenti.

Esempio 1.1.2 (Passeggiata aleatoria simmetrica su $\mathbb{Z}_n$). Sia $n \geq 3$ un intero e consideriamo la catena che ha come spazio degli stati il gruppo $\mathbb{Z}_n$ degli interi modulo n e matrice di transizione

$$P(j, k) = \begin{cases} 1/2 & \text{se } k \equiv j + 1 \pmod{n}, \\ 1/2 & \text{se } k \equiv j - 1 \pmod{n}, \\ 0 & \text{altrimenti.} \end{cases}$$

Lo spazio degli stati può essere visualizzato come un insieme di n punti equispaziati su una circonferenza, e la catena procede nel modo seguente: a ogni passo lanciamo una moneta equilibrata. Se esce testa, facciamo un passo in senso orario, altrimenti facciamo un passo in senso antiorario.

Se n è pari, la catena è periodica. Se si parte ad esempio da uno stato pari x_0 , la quantità $P^{2t}(x_0, \cdot)$ è positiva solo sugli stati pari, mentre $P^{2t+1}(x_0, \cdot)$ è positiva solo sugli stati dispari. Dunque P^t non converge per $t \rightarrow \infty$.




Figura 1.1.1: La passeggiata aleatoria simmetrica su $\mathbb{Z}_8$ è periodica, dato che con un passo è possibile passare solo da uno stato pari a uno dispari, o viceversa.

In generale, se una catena irriducibile (X_t) è periodica, dato un qualunque stato iniziale x , la distribuzione di probabilità $P^t(x, \cdot)$ non può convergere per $t \rightarrow \infty$. Fortunatamente, una semplice modifica può risolvere problemi di periodicità. Data una qualsiasi matrice di transizione P , sia $Q = \frac{I+P}{2}$ (dove I è la matrice identità di taglia $|\mathcal{X}| \times |\mathcal{X}|$). La passeggiata aleatoria con matrice di transizione Q procede nel seguente modo: a ogni passo, lanciamo una moneta equilibrata. Se esce testa, ci muoviamo secondo P , altrimenti restiamo nello stato corrente. Dato che $Q(x, x) > 0$ per ogni $x \in \mathcal{X}$, la matrice di transizione Q è aperiodica. Chiamiamo Q la versione **lazy** di P . Ci sarà utile spesso considerare la versione lazy della catena che stiamo studiando.

Dall'equazione (1.1.2) si deduce che, se la distribuzione ν_t di X_t ammette un limite π per $t \rightarrow \infty$, questo deve soddisfare $\pi = \pi P$. Introduciamo quindi il concetto di *distribuzione stazionaria*.

Definizione 1.1.3. Una *distribuzione stazionaria* di una catena di Markov con matrice di transizione P e spazio degli stati $\mathcal{X}$ è una misura di probabilità π definita su $\mathcal{X}$ tale che

$$\pi = \pi P.$$

Proposizione 1.1.4. Sia P la matrice di transizione di una catena irriducibile a stati finiti. Allora esiste un'unica distribuzione di probabilità π tale che $\pi = \pi P$.

Una dimostrazione di questo risultato si trova in [LP17, Corollario 1.17].

Per misurare la distanza tra le misure di probabilità $P^t(x, \cdot)$ e π , solitamente si usa la **distanza in variazione totale**, di cui segue la definizione.

Definizione 1.1.5. La *distanza in variazione totale* tra due misure di probabilità μ e ν su un insieme finito $\mathcal{X}$ è definita come

$$\|\mu - \nu\|_{\text{TV}} = \max_{A \subseteq \mathcal{X}} |\mu(A) - \nu(A)|.$$

La distanza tra μ e ν è quindi la massima differenza tra le probabilità assegnate a un singolo evento dalle due distribuzioni.

Il seguente teorema, centrale nella teoria delle catene di Markov, garantisce che la distribuzione di una catena irriducibile e aperiodica tenda alla distribuzione stazionaria.

Teorema 1.1.6. Sia P la matrice di transizione di una catena a stati finiti irriducibile e aperiodica con distribuzione stazionaria π . Allora esistono due costanti $\alpha \in (0, 1)$ e $C > 0$ tali che

$$\max_{x \in \mathcal{X}} \|P^t(x, \cdot) - \pi\|_{\text{TV}} \leq C\alpha^t.$$

Una dimostrazione si trova in [LP17, Capitolo 4].

Altre due definizioni di cui faremo uso nei capitoli successivi sono le seguenti:

Definizione 1.1.7. Una catena con matrice di transizione P e distribuzione stazionaria π è detta *reversibile* se per ogni $x, y \in \mathcal{X}$ vale $\pi(x)P(x, y) = \pi(y)P(y, x)$.

Informalmente, questo corrisponde al fatto che, una volta raggiunta la distribuzione stazionaria, risulta impossibile distinguere se la catena stia procedendo in avanti o indietro nel tempo.

Definizione 1.1.8. Una catena di Markov è detta *transitiva* se per ogni coppia di stati $(x, y) \in \mathcal{X} \times \mathcal{X}$ esiste una bigezione $\varphi = \varphi_{x,y} : \mathcal{X} \rightarrow \mathcal{X}$ tale che

$$\varphi(x) = y \quad \text{e} \quad P(z, w) = P(\varphi(z), \varphi(w)) \quad \text{per ogni } z, w \in \mathcal{X}.$$

Informalmente, questo significa che la catena “sembra la stessa” da ogni stato iniziale $x \in \mathcal{X}$.

1.2 Passeggiate aleatorie su gruppi

Molte delle catene che esamineremo in questo elaborato saranno *passeggiate aleatorie su gruppi*, che definiamo di seguito.

Definizione 1.2.1. Sia G un gruppo finito e sia μ una misura di probabilità su G . Chiamiamo passeggiata aleatoria su G con transizioni date da μ la catena di Markov con spazio degli stati G e matrice di transizione P data da

$$P(g, hg) = \mu(h).$$

In altre parole, la catena procede da uno stato al successivo moltiplicando lo stato corrente a sinistra per un elemento casuale di G selezionato secondo μ .

Esempio 1.2.2 (Trasposizioni aleatorie). Supponiamo di avere un mazzo di n carte che mescoliamo nel seguente modo: a ogni passo t scegliamo in maniera uniforme e indipendente una carta R_t con la mano destra e una carta L_t con la mano sinistra. Se L_t e R_t sono diverse, le scambiamo.

Sia π_t la permutazione delle n carte ottenuta al tempo t . Scambiando le carte L_t, R_t si ottiene la permutazione $(L_t, R_t) \circ \pi_t$, quindi questo modo di mescolare le carte corrisponde alla passeggiata aleatoria sul gruppo S_n con transizioni date da

$$\mu(\sigma) = \begin{cases} \frac{1}{n}, & \text{se } \sigma = \text{id}, \\ \frac{2}{n^2}, & \text{se } \sigma = (ij), \\ 0, & \text{altrimenti.} \end{cases}$$

Dimostriamo ora alcune proprietà fondamentali delle passeggiate aleatorie su gruppi.

Proposizione 1.2.3. Sia P la matrice di transizione di una passeggiata aleatoria su un gruppo G e sia U la distribuzione uniforme su G . Allora U è una distribuzione stazionaria per P .

Dimostrazione. Sia μ la distribuzione degli incrementi della passeggiata aleatoria. Per ogni $g \in G$,

$$\sum_{h \in G} U(h)P(h, g) = \frac{1}{|G|} \sum_{h \in G} \mu(gh^{-1}) = \frac{1}{|G|} \sum_{k \in G} \mu(k) = \frac{1}{|G|} = U(g).$$

□

Proposizione 1.2.4. Sia P la matrice di transizione di una passeggiata aleatoria su un gruppo G con transizioni date da μ . Se μ è simmetrica, ovvero se $\mu(g) = \mu(g^{-1})$ per ogni $g \in G$, allora la catena è reversibile rispetto alla distribuzione uniforme U .

Dimostrazione. Bisogna verificare che per ogni $g, h \in G$ vale

$$U(g)P(g, h) = U(h)P(h, g),$$

ovvero che $\mu(hg^{-1}) = \mu(gh^{-1})$. Questo segue dal fatto che μ è simmetrica. $\square$

Notiamo inoltre che le passeggiate aleatorie su gruppi sono catene transitive: usando la notazione della Definizione 1.1.8, per ogni coppia $(x, y) \in \mathcal{X} \times \mathcal{X}$, poniamo $\varphi_{x,y}(g) = gx^{-1}y$.

Per le passeggiate aleatorie su gruppi, la distribuzione della catena al tempo t assume una forma specifica. Sia ν_t la distribuzione di X_t :

$$\nu_t(x) = \mathbf{P}\{X_t = x\} \quad \text{per ogni } x \in \mathcal{X}.$$

L'Equazione (1.1.1) assume la forma

$$\nu_{t+1}(g) = \sum_{h \in G} \mathbf{P}\{X_t = h\}P(h, g) = \sum_{h \in G} \nu_t(h)\mu(gh^{-1}) \quad \text{per ogni } g \in G.$$

Quindi, se definiamo il *prodotto di convoluzione* tra due misure di probabilità μ, ν su un gruppo finito G come

$$(1.2.1) \quad (\mu * \nu)(g) = \sum_{h \in G} \mu(gh^{-1})\nu(h),$$

otteniamo

$$\nu_t = \mu^{*t} * \nu_0,$$

dove μ^{*t} indica la convoluzione di μ con se stessa t volte. Introduciamo infine due definizioni di cui faremo uso nel Capitolo 3.

1.3 Speranza condizionale

Nella sezione dedicata ai tempi d'arresto, useremo le σ -algebre per descrivere le informazioni disponibili fino a un certo tempo. La **speranza condizionale** è lo strumento che permette di riformulare la definizione di catena di Markov condizionando non soltanto rispetto a un evento, ma rispetto a una σ -algebra. Ne richiamiamo la definizione, seguendo [Wil91, Capitolo 9].

Definizione 1.3.1. Sia $(\Omega, \mathcal{A}, \mathbf{P})$ uno spazio di probabilità, sia X una variabile aleatoria integrabile, ovvero tale che $\mathbf{E}[|X|] < \infty$, e sia $\mathcal{F} \subseteq \mathcal{A}$ una σ -algebra. Una *speranza condizionale* di X rispetto a $\mathcal{F}$ è una variabile aleatoria Y tale che:

- Y è $\mathcal{F}$ -misurabile;
- Y è integrabile;
- per ogni evento $A \in \mathcal{F}$ vale $\mathbf{E}[Y\mathbf{1}_A] = \mathbf{E}[X\mathbf{1}_A]$.

Si può dimostrare che tale variabile esiste ed è unica a meno di un insieme di probabilità nulla. La indicheremo con

$$Y = \mathbf{E}[X \mid \mathcal{F}].$$

La speranza condizionale può essere interpretata come la migliore approssimazione di X data l'informazione contenuta nella σ -algebra $\mathcal{F}$. Più precisamente, se $X \in L^2$, allora $\mathbf{E}[X \mid \mathcal{F}]$ minimizza la quantità $\mathbf{E}[(X - Y)^2]$ tra tutte le variabili aleatorie Y che sono $\mathcal{F}$ -misurabili e appartengono a L^2 .

1.4 Norma ℓ^p

Definiamo una norma sullo spazio vettoriale $\mathbb{R}^{\mathcal{X}}$ delle funzioni dallo spazio degli stati $\mathcal{X}$ ad $\mathbb{R}$, che sarà utile nello studiare le proprietà spettrali della matrice di transizione P .

Definizione 1.4.1. Data una misura di probabilità π su $\mathcal{X}$ e p che soddisfa $1 \leq p \leq \infty$, la *norma* $\ell^p(\pi)$ di una funzione $f : \mathcal{X} \rightarrow \mathbb{R}$ è definita come

$$\|f\|_p := \begin{cases} \left[\sum_{y \in \mathcal{X}} |f(y)|^p \pi(y) \right]^{1/p} & \text{se } 1 \leq p < \infty, \\ \max_{y \in \mathcal{X}} |f(y)| & \text{se } p = \infty. \end{cases}$$

In questo elaborato faremo uso solo dei casi $p = 1$, $p = 2$ e $p = \infty$.

Capitolo 2

Introduzione al mixing

2.1 Distanza dalla stazionarietà e mixing time

La domanda principale a cui cerchiamo di rispondere in questo elaborato è: quanto tempo deve passare affinché una catena di Markov sia vicina alla sua distribuzione stazionaria?

Ad esempio, nel caso delle trasposizioni aleatorie descritte nell'Esempio 1.2.2 la domanda diventa: quante trasposizioni scelte in maniera uniforme e indipendente sono necessarie affinché il mazzo sia approssimativamente mischiato?

Per rispondere in modo preciso a queste domande, presentiamo alcune definizioni e proprietà di base, seguendo [LP17, Capitolo 4].

Sia $(X_t)_{t \in \mathbb{N}}$ una catena di Markov con spazio degli stati $\mathcal{X}$, matrice di transizione P e distribuzione stazionaria π . Vogliamo studiare la quantità

$$(2.1.1) \quad d(t) := \max_{x \in \mathcal{X}} \|P^t(x, \cdot) - \pi\|_{\text{TV}},$$

detta distanza dalla stazionarietà. Essa indica la distanza in variazione totale dalla distribuzione stazionaria quando la catena parte dal peggior possibile stato.

Il Teorema 1.1.6 garantisce che, per catene irriducibili e aperiodiche, $\lim_{t \rightarrow \infty} d(t) = 0$.

Possiamo quindi dare la definizione di *mixing time*:

Definizione 2.1.1. Data una catena di Markov (X_t) e $\varepsilon > 0$, il mixing time della catena (X_t) è definito come

$$t_{\text{mix}}(\varepsilon) := \min\{t : d(t) \leq \varepsilon\};$$

poniamo inoltre

$$t_{\text{mix}} := t_{\text{mix}}\left(\frac{1}{4}\right).$$

2.2 Distanza in variazione totale e coupling

Procediamo ora a esaminare alcune proprietà della distanza in variazione totale e della funzione $d(t)$ che ci saranno utili in seguito.

Proposizione 2.2.1. Date μ e ν due probabilità su $\mathcal{X}$, vale

$$\|\mu - \nu\|_{\text{TV}} = \frac{1}{2} \sum_{x \in \mathcal{X}} |\mu(x) - \nu(x)|.$$

Dimostrazione. Sia $B := \{x \in \mathcal{X} : \mu(x) \geq \nu(x)\}$ e sia $A \subseteq \mathcal{X}$ un qualsiasi evento. Abbiamo

$$(2.2.1) \quad \mu(A) - \nu(A) \leq \mu(A \cap B) - \nu(A \cap B) \leq \mu(B) - \nu(B).$$

La prima disuguaglianza segue dal fatto che ogni $x \in A \cap B^c$ soddisfa $\mu(x) - \nu(x) < 0$, quindi la quantità $\mu(A) - \nu(A)$ non può che aumentare eliminando gli elementi di $A \cap B^c$. La seconda disuguaglianza segue dal fatto che gli elementi di B soddisfano $\mu(x) - \nu(x) \geq 0$.

Analogamente si ottiene

$$(2.2.2) \quad \nu(A) - \mu(A) \leq \nu(B^c) - \mu(B^c).$$

Le stime dall'alto ottenute nelle equazioni (2.2.1) e (2.2.2) sono uguali: infatti $(\mu(B) - \nu(B)) - (\nu(B^c) - \mu(B^c)) = 0$. Inoltre, se $A = B$ tale stima dall'alto è effettivamente raggiunta. Quindi

$$\|\mu - \nu\|_{\text{TV}} = \frac{1}{2} [\mu(B) - \nu(B) + \nu(B^c) - \mu(B^c)] = \frac{1}{2} \sum_{x \in \mathcal{X}} |\mu(x) - \nu(x)|.$$

□

Usando questa proposizione possiamo dimostrare che la funzione $d(t)$ è decrescente in t , ovvero che avanzare la catena può solo renderla più vicina alla stazionarietà. Per farlo, dimostriamo prima la seguente disuguaglianza: date una matrice di transizione P e due distribuzioni di probabilità μ e ν su $\mathcal{X}$, vale

$$\|\mu P - \nu P\|_{\text{TV}} \leq \|\mu - \nu\|_{\text{TV}}.$$

Infatti si ha

$$\begin{aligned} \|\mu P - \nu P\|_{\text{TV}} &= \frac{1}{2} \sum_{y \in \mathcal{X}} \left| \sum_{x \in \mathcal{X}} (\mu(x) - \nu(x)) P(x, y) \right| \\ &\leq \frac{1}{2} \sum_{y \in \mathcal{X}} \sum_{x \in \mathcal{X}} |\mu(x) - \nu(x)| P(x, y) \\ &= \frac{1}{2} \sum_{x \in \mathcal{X}} |\mu(x) - \nu(x)| \sum_{y \in \mathcal{X}} P(x, y) \\ &= \frac{1}{2} \sum_{x \in \mathcal{X}} |\mu(x) - \nu(x)| = \|\mu - \nu\|_{\text{TV}}. \end{aligned}$$

Applicando questa disuguaglianza a $\mu = P^t(x, \cdot)$ e $\nu = \pi$, e usando il fatto che $\pi P = \pi$, otteniamo

$$\|P^{t+1}(x, \cdot) - \pi\|_{\text{TV}} = \|(P^t(x, \cdot) - \pi)P\|_{\text{TV}} \leq \|P^t(x, \cdot) - \pi\|_{\text{TV}}.$$

Prendendo il massimo al variare di $x \in \mathcal{X}$, si ha

$$d(t+1) \leq d(t),$$

come voluto.

Vediamo adesso che un'altra interpretazione della distanza in variazione totale è data dal suo collegamento con il coupling, una tecnica molto utile che verrà esaminata nel Capitolo 3.

Definizione 2.2.2. Un *coupling* di due distribuzioni di probabilità μ e ν è una coppia di variabili aleatorie (X, Y) definite sullo stesso spazio di probabilità tali che la distribuzione marginale di X sia μ e la distribuzione marginale di Y sia ν .

Esempio 2.2.3. Siano μ e ν le distribuzioni che assegnano probabilità $\frac{1}{2}$ a ciascuno degli elementi di $\{0, 1\}$.

- (i) Un modo di fare un coupling tra μ e ν è definire (X, Y) come una coppia di variabili aleatorie bernoulliane indipendenti di parametro $\frac{1}{2}$, quindi $\mathbf{P}(X = x, Y = y) = \frac{1}{4}$ per ogni $x, y \in \{0, 1\}$.
- (ii) Un altro modo è definire X come una bernoulliana di parametro $\frac{1}{2}$ e poi porre $Y = X$. In questo caso, $\mathbf{P}(X = Y = 0) = \frac{1}{2}$, $\mathbf{P}(X = Y = 1) = \frac{1}{2}$ e $\mathbf{P}(X \neq Y) = 0$.

Proposizione 2.2.4. Siano μ e ν due distribuzioni di probabilità su $\mathcal{X}$; vale

$$\|\mu - \nu\|_{\text{TV}} = \inf\{\mathbf{P}\{X \neq Y\} : (X, Y) \text{ è un coupling di } \mu \text{ e } \nu\}.$$

Dimostrazione. Sia (X, Y) un coupling di μ e ν . Per ogni $A \subseteq \mathcal{X}$,

$$\begin{aligned} \mu(A) - \nu(A) &= \mathbf{P}(X \in A) - \mathbf{P}(Y \in A) \\ &= \mathbf{P}(X \in A, Y \notin A) - \mathbf{P}(X \notin A, Y \in A) \\ &\leq \mathbf{P}(X \in A, Y \notin A) \leq \mathbf{P}(X \neq Y). \end{aligned}$$

Scambiando i ruoli di μ e ν si ottiene anche $\nu(A) - \mu(A) \leq \mathbf{P}(X \neq Y)$, da cui segue che

$$\|\mu - \nu\|_{\text{TV}} \leq \inf\{\mathbf{P}\{X \neq Y\} : (X, Y) \text{ è un coupling di } \mu \text{ e } \nu\}.$$

Resta da costruire un coupling (X, Y) tale che $\mathbf{P}(X \neq Y)$ sia uguale a $\|\mu - \nu\|_{\text{TV}}$; vogliamo quindi massimizzare la probabilità dell'evento $\{X = Y\}$. Per illustrare l'idea della dimostrazione, facciamo riferimento alla Figura 2.2.1. La regione delimitata da $\mu(x) \wedge \nu(x)$ rappresenta la parte in comune delle due distribuzioni. Scegliamo prima

un punto sotto il grafico di μ , cioè nell'unione delle regioni I e III, e poniamo X uguale all'ascissa corrispondente. Se il punto cade nella regione comune III, poniamo anche $Y = X$. Se invece cade nella regione I, allora scegliamo un nuovo punto, indipendentemente, nella regione II della distribuzione ν , e definiamo Y come la sua ascissa. In questo secondo caso si ha necessariamente $X \neq Y$, perché le regioni I e II non hanno punti con la stessa ascissa.




Figura 2.2.1: La parte comune alle distribuzioni è la regione III, con area $1 - \|\mu - \nu\|_{\text{TV}}$, mentre le regioni I e II hanno area $\|\mu - \nu\|_{\text{TV}}$. La figura è ispirata a [LP17, Figura 4.2].

Formalmente, sia

$$p := \sum_{x \in \mathcal{X}} \mu(x) \wedge \nu(x).$$

Osserviamo che per ogni $x \in \mathcal{X}$ vale

$$\mu(x) \wedge \nu(x) = \frac{\mu(x) + \nu(x) - |\mu(x) - \nu(x)|}{2}.$$

Sommando su x otteniamo

$$p = 1 - \frac{1}{2} \sum_{x \in \mathcal{X}} |\mu(x) - \nu(x)| = 1 - \|\mu - \nu\|_{\text{TV}},$$

dove nell'ultima uguaglianza abbiamo usato la Proposizione 2.2.1.

Lanciamo una moneta con probabilità di testa uguale a p . Se esce testa, scegliamo un valore Z con distribuzione

$$\gamma_{\text{III}}(x) = \frac{\mu(x) \wedge \nu(x)}{p},$$

e poniamo $X = Y = Z$.

Se esce croce, definiamo le distribuzioni di probabilità

$$\gamma_{\text{I}}(x) = \frac{\mu(x) - \mu(x) \wedge \nu(x)}{1 - p}, \quad \gamma_{\text{II}}(x) = \frac{\nu(x) - \mu(x) \wedge \nu(x)}{1 - p},$$

e scegliamo X con distribuzione γ_{I} e Y con distribuzione γ_{II} , in modo indipendente. Dato che per ogni $x \in \mathcal{X}$ almeno una tra le quantità $\mu(x) - \mu(x) \wedge \nu(x)$ e $\nu(x) - \mu(x) \wedge \nu(x)$

è nulla, le due distribuzioni γ_I e γ_{II} hanno supporti disgiunti. Quindi, in questo secondo caso, si ha $X \neq Y$ quasi certamente.

È chiaro che

$$p\gamma_{III} + (1-p)\gamma_I = \mu,$$

$$p\gamma_{III} + (1-p)\gamma_{II} = \nu,$$

quindi la distribuzione marginale di X è μ e la distribuzione marginale di Y è ν . Inoltre, per quanto detto, si ha $X = Y$ se e solo se esce testa. Abbiamo quindi costruito un coupling (X, Y) di μ e ν tale che

$$\mathbf{P}(X \neq Y) = 1 - p = \|\mu - \nu\|_{TV},$$

che conclude la dimostrazione. $\square$

2.3 Distanza $\bar{d}$ e submoltiplicatività

Spesso al posto di usare la distanza dalla stazionarietà $d(t)$ è più conveniente usare la distanza

$$(2.3.1) \quad \bar{d}(t) := \max_{x, y \in \mathcal{X}} \|P^t(x, \cdot) - P^t(y, \cdot)\|_{TV},$$

perché, come vedremo, la funzione $\bar{d}(t)$ è submoltiplicativa, mentre $d(t)$ non lo è.

Proposizione 2.3.1. La funzione $\bar{d}$ è submoltiplicativa: vale $\bar{d}(s+t) \leq \bar{d}(s)\bar{d}(t)$.

Dimostrazione. Fissiamo due stati iniziali $x, y \in \mathcal{X}$. Vogliamo stimare la distanza tra $P^{s+t}(x, \cdot)$ e $P^{s+t}(y, \cdot)$ costruendo un coupling delle due distribuzioni.

Sia (X_s, Y_s) un coupling ottimale di $P^s(x, \cdot)$ e $P^s(y, \cdot)$, cioè tale che

$$\mathbf{P}(X_s \neq Y_s) = \|P^s(x, \cdot) - P^s(y, \cdot)\|_{TV},$$

che esiste per la Proposizione 2.2.4.

Ora costruiamo il coupling al tempo $s+t$. Supponiamo che al tempo s si abbia $X_s = a$ e $Y_s = b$. Se $a = b$, facciamo proseguire le due copie insieme: data una variabile Z con distribuzione $P^t(a, \cdot)$, poniamo $X_{s+t} = Y_{s+t} = Z$. Se invece $a \neq b$, sia (X_{s+t}, Y_{s+t}) un coupling ottimale di $P^t(a, \cdot)$ e $P^t(b, \cdot)$. In altre parole, condizionatamente a $X_s = a$ e $Y_s = b$, il vettore (X_{s+t}, Y_{s+t}) ha distribuzioni marginali uguali rispettivamente a $P^t(a, \cdot)$ e $P^t(b, \cdot)$, ed è tale che

$$\mathbf{P}(X_{s+t} \neq Y_{s+t} \mid X_s = a, Y_s = b) = \|P^t(a, \cdot) - P^t(b, \cdot)\|_{TV}.$$

Questa costruzione fornisce un coupling di $P^{s+t}(x, \cdot)$ e $P^{s+t}(y, \cdot)$: per ogni $z \in \mathcal{X}$,

$$\mathbf{P}(X_{s+t} = z) = \sum_{a \in \mathcal{X}} \mathbf{P}(X_s = a) P^t(a, z) = \sum_{a \in \mathcal{X}} P^s(x, a) P^t(a, z) = P^{s+t}(x, z),$$

e analogamente Y_{s+t} ha distribuzione $P^{s+t}(y, \cdot)$.

Per la Proposizione 2.2.4,

$$\|P^{s+t}(x, \cdot) - P^{s+t}(y, \cdot)\|_{\text{TV}} \leq \mathbf{P}(X_{s+t} \neq Y_{s+t}).$$

Stimiamo tale probabilità condizionando rispetto a (X_s, Y_s) . Se $X_s = Y_s$, le due copie vengono fatte evolvere insieme, quindi non possono essere diverse al tempo $s+t$. Se invece $X_s \neq Y_s$, la probabilità condizionata di essere diverse dopo altri t passi è al più $\bar{d}(t)$. Dunque

$$\begin{aligned} \mathbf{P}(X_{s+t} \neq Y_{s+t}) &\leq \mathbf{P}(X_s \neq Y_s) \bar{d}(t) \\ &= \|P^s(x, \cdot) - P^s(y, \cdot)\|_{\text{TV}} \bar{d}(t) \\ &\leq \bar{d}(s) \bar{d}(t). \end{aligned}$$

Abbiamo quindi mostrato che, per ogni $x, y \in \mathcal{X}$,

$$\|P^{s+t}(x, \cdot) - P^{s+t}(y, \cdot)\|_{\text{TV}} \leq \bar{d}(s) \bar{d}(t).$$

Prendendo il massimo su x e y , otteniamo

$$\bar{d}(s+t) \leq \bar{d}(s) \bar{d}(t).$$

□

Resta da collegare questa nuova distanza alla distanza dalla stazionarietà. Il prossimo risultato mostra che le due quantità sono confrontabili, a meno di un fattore 2.

Proposizione 2.3.2. Le funzioni $d(t)$ e $\bar{d}(t)$ soddisfano

$$d(t) \leq \bar{d}(t) \leq 2d(t).$$

Dimostrazione. È chiaro dalla disuguaglianza triangolare che $\bar{d}(t) \leq 2d(t)$. Dimostriamo quindi che $d(t) \leq \bar{d}(t)$. Notiamo che, per definizione di distribuzione stazionaria, vale $\pi(x) = \sum_{y \in \mathcal{X}} \pi(y) P^t(y, x)$, da cui, sommando su tutti gli elementi di un sottoinsieme A di $\mathcal{X}$, si ottiene $\pi(A) = \sum_{y \in \mathcal{X}} \pi(y) P^t(y, A)$. Dunque

$$\begin{aligned} |P^t(x, A) - \pi(A)| &= \left| \sum_{y \in \mathcal{X}} \pi(y) [P^t(x, A) - P^t(y, A)] \right| \\ &\leq \sum_{y \in \mathcal{X}} \pi(y) \|P^t(x, \cdot) - P^t(y, \cdot)\|_{\text{TV}} \leq \bar{d}(t) \end{aligned}$$

□

Usando la submoltiplicatività della funzione $\bar{d}(t)$ e la Proposizione 2.3.2 si ottiene che, se t e k sono interi positivi,

$$(2.3.2) \quad d(kt) \leq \bar{d}(kt) \leq \bar{d}(t)^k \leq (2d(t))^k.$$

Sostituendo $t = t_{\text{mix}}(\varepsilon)$ in quest'ultima disuguaglianza si ha

$$(2.3.3) \quad d(kt_{\text{mix}}(\varepsilon)) \leq \bar{d}(t_{\text{mix}}(\varepsilon))^k \leq (2\varepsilon)^k.$$

In particolare, per $\varepsilon = \frac{1}{4}$ si ottiene

$$d(kt_{\text{mix}}) \leq 2^{-k},$$

e

$$(2.3.4) \quad t_{\text{mix}}(\varepsilon) \leq \lceil \log_2 \varepsilon^{-1} \rceil t_{\text{mix}}.$$

Quindi, anche se la scelta di $\frac{1}{4}$ è arbitraria nella Definizione 2.1.1 di t_{mix} , è necessario un valore di ε minore di $\frac{1}{2}$ per far sì che la disuguaglianza $d(kt_{\text{mix}}(\varepsilon)) \leq (2\varepsilon)^k$ in (2.3.3) sia significativa e per ottenere una disuguaglianza della forma (2.3.4).

Capitolo 3

Tecniche

In questo capitolo esaminiamo alcune delle principali tecniche che permettono di stimare il mixing time di catene di Markov a stati finiti.

3.1 Coupling

Questa sezione segue la trattazione del coupling in [LP17, Capitolo 5].

Ricordiamo la Definizione 2.2.2: un coupling di due distribuzioni di probabilità μ e ν è una coppia di variabili aleatorie (X, Y) , definite sullo stesso spazio di probabilità, tali che la distribuzione marginale di X sia μ e quella di Y sia ν . La Proposizione 2.2.4 caratterizza $\|\mu - \nu\|_{\text{TV}}$ come il minimo della probabilità $\mathbf{P}(X \neq Y)$ al variare di tutti i coupling (X, Y) di μ e ν . Per stimare dall'alto la quantità $\|\mu - \nu\|_{\text{TV}}$ vogliamo quindi costruire un coupling in cui le due variabili coincidono con probabilità elevata.

In questa sezione sfrutteremo questo principio per stimare dall'alto il mixing time di alcune catene. L'idea è di applicarlo non a due singole distribuzioni, ma a due intere copie della catena: le faremo partire da stati iniziali diversi e le costruiremo in modo che tendano a incontrarsi rapidamente. Una volta avvenuto l'incontro, le lasceremo proseguire insieme, e il tempo necessario perché ciò accada fornirà una stima dall'alto della distanza dalla stazionarietà.

3.1.1 Coupling di catene

Consideriamo una catena di Markov con matrice di transizione P e spazio $\mathcal{X}$. Cominciamo formalizzando la nozione di coupling di due copie della catena.

Definizione 3.1.1. Un coupling di due catene di Markov con matrice di transizione P è una coppia di processi $(X_t, Y_t)_{t \geq 0}$, definiti sullo stesso spazio di probabilità, tali che (X_t) e (Y_t) , considerate separatamente, siano catene di Markov con matrice di transizione P , eventualmente con distribuzioni iniziali diverse.

Il coupling è detto *markoviano* se il processo (X_t, Y_t) è una catena di Markov su $\mathcal{X} \times \mathcal{X}$ e, per ogni $x, y, x', y' \in \mathcal{X}$,

$$\begin{aligned}\mathbf{P}(X_{t+1} = x' \mid X_t = x, Y_t = y) &= P(x, x'), \\ \mathbf{P}(Y_{t+1} = y' \mid X_t = x, Y_t = y) &= P(y, y').\end{aligned}$$

Nelle applicazioni costruiremo sempre dei coupling markoviani, in modo da studiarli tramite le probabilità di transizione.

In un coupling le due copie possono evolvere in modo correlato: l'importante è che, osservate singolarmente, siano catene di Markov con matrice di transizione P . Sfrutteremo proprio questa libertà nella scelta della legge congiunta per cercare di massimizzare la probabilità $\mathbf{P}(X_t = Y_t)$. Imponiamo che, una volta che le due copie si sono incontrate, non si separino più, ovvero che

$$(3.1.1) \quad X_s = Y_s \implies X_t = Y_t \text{ per ogni } t \geq s.$$

Dato un qualunque coupling, possiamo sempre modificarlo facendo evolvere insieme le due copie a partire dall'istante in cui si incontrano, senza cambiarne le distribuzioni marginali.

Definizione 3.1.2. Sia (X_t, Y_t) un coupling che soddisfa (3.1.1). Il *tempo di coupling*, o tempo di coalescenza, è

$$\tau_{\text{coup}} := \min\{t \geq 0 : X_t = Y_t\}.$$

Il legame tra il tempo di coalescenza e la distanza dalla stazionarietà è espresso dalla seguente proposizione, che è l'analogo per le catene di Markov della Proposizione 2.2.4.

Proposizione 3.1.3 (Disuguaglianza di coupling). Sia (X_t, Y_t) un coupling che soddisfa (3.1.1), con $X_0 = x$ e $Y_0 = y$. Allora, per ogni $t \geq 0$,

$$\|P^t(x, \cdot) - P^t(y, \cdot)\|_{\text{TV}} \leq \mathbf{P}_{x,y}(\tau_{\text{coup}} > t).$$

Dimostrazione. Dato che $X_0 = x$ e $Y_0 = y$, le variabili X_t e Y_t hanno distribuzioni rispettivamente $P^t(x, \cdot)$ e $P^t(y, \cdot)$, e quindi la coppia (X_t, Y_t) ne costituisce un coupling. Dalla Proposizione 2.2.4 segue che

$$\|P^t(x, \cdot) - P^t(y, \cdot)\|_{\text{TV}} \leq \mathbf{P}_{x,y}(X_t \neq Y_t).$$

Per la proprietà (3.1.1), l'evento $\{X_t \neq Y_t\}$ coincide con $\{\tau_{\text{coup}} > t\}$, da cui segue la tesi. $\square$

Corollario 3.1.4. Supponiamo che, per ogni coppia di stati $x, y \in \mathcal{X}$, sia dato un coupling con tempo di coalescenza $\tau_{\text{coup}}^{x,y}$. Allora

$$d(t) \leq \max_{x,y \in \mathcal{X}} \mathbf{P}_{x,y}(\tau_{\text{coup}}^{x,y} > t).$$

Se inoltre

$$\max_{x,y \in \mathcal{X}} \mathbf{E}_{x,y}[\tau_{\text{coup}}^{x,y}] \leq T,$$

allora $t_{\text{mix}} \leq 4T$.

Dimostrazione. La prima disuguaglianza si ottiene prendendo il massimo su x, y nella Proposizione 3.1.3 e ricordando che $d(t) \leq \bar{d}(t)$. Per la seconda affermazione usiamo la disuguaglianza di Markov: per $t = 4T$ si ha

$$\max_{x,y} \mathbf{P}_{x,y}(\tau_{\text{coup}}^{x,y} > 4T) \leq \frac{\max_{x,y} \mathbf{E}_{x,y}[\tau_{\text{coup}}^{x,y}]}{4T} \leq \frac{1}{4}.$$

Combinando con la prima parte dell'enunciato si ha allora $d(4T) \leq \bar{d}(4T) \leq \frac{1}{4}$, da cui $t_{\text{mix}} \leq 4T$. $\square$

Illustriamo la tecnica appena descritta con un esempio.

Esempio 3.1.5. Consideriamo la passeggiata aleatoria simmetrica lazy su $\mathbb{Z}_n$ descritta nell'Esempio 1.1.2, con matrice di transizione $Q = \frac{I+P}{2}$. Mostriamo, tramite il Corollario 3.1.4, che $t_{\text{mix}} \leq n^2$.

Costruiamo un coupling (X_t, Y_t) , con $X_0 = x$ e $Y_0 = y$, nel modo seguente: a ogni passo lanciamo una moneta equilibrata per scegliere quale delle due copie muovere. La copia selezionata si muove di $+1$ o di -1 con uguale probabilità, mentre l'altra resta ferma. Da quando le due copie si incontrano procedono nello stesso modo, in accordo con (3.1.1).

Consideriamo ora la differenza $D_t = (X_t - Y_t) \bmod n$, che misura la distanza tra le due copie lungo la circonferenza. Finché esse non si sono incontrate, a ogni passo esattamente una delle due si muove di ± 1 , e quindi D_t varia di ± 1 . Da quando si incontrano, $D_t \equiv 0 \pmod{n}$. Quindi (D_t) può essere pensato come una catena di Markov sull'insieme $\{0, 1, \dots, n\}$ che si muove di ± 1 con probabilità $\frac{1}{2}$ ciascuno quando si trova in $\{1, 2, \dots, n-1\}$, e che resta ferma quando si trova in $\{0, n\}$. Il tempo di coalescenza τ_{coup} è il primo istante in cui $D_t \in \{0, n\}$. Posto $k := (x - y) \bmod n$, stimiamo la quantità $\mathbf{E}_k[\tau_{\text{coup}}]$ per applicare il Corollario 3.1.4.

Sia quindi $h(k) := \mathbf{E}_k[\tau_{\text{coup}}]$ per $k \in \{0, 1, \dots, n\}$. Condizionando sull'esito del primo passo si ottengono le relazioni

$$h(0) = h(n) = 0, \quad h(k) = 1 + \frac{1}{2}h(k-1) + \frac{1}{2}h(k+1) \quad \text{per } 1 \leq k \leq n-1.$$

Si verifica facilmente che la soluzione del sistema è data da $h(k) = k(n-k)$, ovvero che

$$\mathbf{E}_k[\tau_{\text{coup}}] = k(n-k).$$

Per la disuguaglianza tra media aritmetica e geometrica si ha $k(n-k) \leq \frac{n^2}{4}$ per ogni k , e quindi

$$\max_{x,y \in \mathbb{Z}_n} \mathbf{E}_{x,y}[\tau_{\text{coup}}] \leq \frac{n^2}{4}.$$

Il Corollario 3.1.4, applicato con $T = \frac{n^2}{4}$, fornisce

$$t_{\text{mix}} \leq 4T = n^2.$$

3.1.2 Grand coupling e cammini su reticoli

Nei coupling considerati finora abbiamo accoppiato due copie della catena. In molte situazioni si può invece costruire simultaneamente una copia della catena per ogni stato iniziale possibile, usando la stessa sequenza di aggiornamenti casuali.

Formalmente, una *rappresentazione tramite aggiornamenti casuali* della matrice di transizione P è data da una funzione

$$F : \mathcal{X} \times \Lambda \rightarrow \mathcal{X},$$

e una variabile aleatoria Z a valori in un insieme Λ tali che

$$\mathbf{P}(F(x, Z) = y) = P(x, y) \quad \text{per ogni } x, y \in \mathcal{X}.$$

Se $(Z_t)_{t \geq 1}$ sono copie indipendenti di Z , ponendo

$$X_0^x = x, \quad X_t^x = F(X_{t-1}^x, Z_t),$$

otteniamo simultaneamente una copia della catena per ogni stato iniziale $x \in \mathcal{X}$. Questa costruzione è detta *grand coupling*.

Il grand coupling è detto *monotono* se esiste un ordine parziale $\preceq$ su $\mathcal{X}$ tale che

$$x \preceq y \implies F(x, z) \preceq F(y, z),$$

per ogni possibile aggiornamento $z \in \Lambda$. In presenza di un minimo $\hat{0}$ e di un massimo $\hat{1}$, la monotonia permette di controllare tutte le traiettorie osservando solo quelle partite da $\hat{0}$ e da $\hat{1}$: se queste due coalescono, allora tutte le copie intermedie sono coalescenti.

Esempio 3.1.6 (Cammini su reticoli). Consideriamo l'insieme $\mathcal{R}_{a,b}$ dei cammini reticolari formati da a passi verso il basso e b passi verso l'alto. Identifichiamo un cammino con una parola $r \in \{0, 1\}^{a+b}$ con esattamente b simboli uguali a 1, in cui il simbolo 1 rappresenta un passo verso l'alto e il simbolo 0 un passo verso il basso.




Figura 3.1.1: Un cammino sul reticolo di dimensioni 4×5 , la cui parola corrispondente è $r = 011011100$. Le caselle sotto il cammino sono ombreggiate. La figura è ispirata a [Wil04, Figura 2].

Consideriamo la catena che ha come spazio degli stati l'insieme $\mathcal{R}_{a,b}$ e che procede nel modo seguente. A ogni passo scegliamo uniformemente una posizione $i \in \{1, \dots, a+b-1\}$ e lanciamo una moneta equilibrata. Se esce testa, sostituiamo la coppia (r_i, r_{i+1}) con la stessa coppia ordinata in modo crescente; se esce croce, la sostituiamo con la coppia ordinata in modo decrescente. Se i due simboli sono uguali, il cammino rimarrà invariato in ogni caso.




Figura 3.1.2: Un possibile passo della catena: se al tempo t viene scelta la posizione $i = 3$ e la coppia viene ordinata in modo crescente, la stringa 10 viene sostituita dalla stringa 01.

Nella rappresentazione tramite aggiornamenti casuali, la variabile aleatoria è la coppia $Z = (i, c)$, dove i è la posizione scelta e c è il risultato della moneta, e $F(r, Z)$ è il cammino ottenuto applicando la regola precedente. Il grand coupling è dato dall'usare la stessa sequenza di aggiornamenti casuali (Z_t) per tutti i cammini iniziali $r \in \mathcal{R}_{a,b}$.

Introduciamo il seguente ordinamento sui cammini basato sulle funzioni

$$H_j(r) := \sum_{i=1}^j r_i,$$

che misurano l'altezza di un cammino dopo j passi. Poniamo $r \preceq r'$ se il cammino r sta sempre sotto il cammino r' , cioè se, per ogni j , si ha $H_j(r) \leq H_j(r')$. Si verifica facilmente per induzione su t che il grand coupling è monotono, ovvero che l'ordine dei cammini viene preservato usando la stessa sequenza di aggiornamenti casuali (Z_t) . Quindi, per controllare la coalescenza del grand coupling, basta confrontare il cammino minimo, in cui i passi verso l'alto sono tutti alla fine, con il cammino massimo, in cui sono tutti all'inizio.

Nel Capitolo 6, seguendo l'impostazione di Wilson [Wil04], vedremo come questo esempio si riconduce alla catena delle trasposizioni adiacenti.

3.2 Strong Stationary Times

In questa sezione esaminiamo una tecnica probabilistica chiamata strong stationary times. La trattazione segue [LP17, Capitolo 6]; la tecnica è stata introdotta da Aldous e Diaconis [AD86, AD87]. Come nella sezione precedente, troveremo un collegamento tra t_{mix} e le code di un tempo aleatorio τ , dove però in questo caso τ è un tempo tale che X_τ abbia distribuzione stazionaria, indipendentemente dal valore di τ . Useremo questo fatto per risolvere numerosi problemi di mixing di passeggiate aleatorie su gruppi.

Per introdurre gli strong stationary times, cominciamo con un esempio informale.

Esempio 3.2.1 (*Top to random shuffle*). Consideriamo il seguente modo di mescolare un mazzo di n carte: a ogni passo prendiamo la carta che si trova in cima e la inseriamo in una posizione del mazzo scelta uniformemente.

Immaginiamo di colorare di rosso la carta che inizialmente si trova in fondo al mazzo. Questa carta rimane in fondo finché una carta non viene inserita sotto di essa. Man mano che la catena evolve, anche una seconda carta sarà inserita sotto la carta rossa. L'ordine relativo delle due carte che si trovano sotto la carta rossa è uniforme: la probabilità che la carta con il numero più alto si trovi sopra o sotto quella con il numero più basso è la stessa. Analogamente, quando una terza carta viene inserita sotto la carta rossa, ciascuno dei sei possibili ordinamenti delle tre carte che si trovano in fondo è ugualmente probabile.

Consideriamo il tempo T in cui la carta rossa è tornata per la prima volta in cima. Induttivamente, otteniamo che tutte le $(n-1)!$ possibili disposizioni delle carte sottostanti sono equiprobabili. Quindi al passo successivo $\tau = T + 1$ la carta rossa viene inserita in una posizione casuale, e tutte le $n!$ permutazioni sono equiprobabili. La Figura 3.2.1 illustra i primi passi di questa costruzione.




Figura 3.2.1: Costruzione dello strong stationary time per il top to random shuffle. Le linee tratteggiate indicano le posizioni sotto la carta rossa in cui può essere inserita la carta in cima.

Quando la carta rossa si trova in posizione i dal basso, il numero di passi per inserire una carta sotto di essa ha distribuzione geometrica di parametro $\frac{i}{n}$. Quindi τ vale in media

$$\mathbf{E}[\tau] = 1 + \sum_{k=1}^{n-1} \frac{n}{k} \approx n \log n.$$

Ci possiamo quindi aspettare che il mixing time della catena sia di ordine $n \log n$.

Per rendere rigoroso l'argomento appena descritto, introduciamo gli strong stationary times.

3.2.1 Tempi di arresto

Il primo passo verso la definizione di strong stationary time è definire i tempi di arresto. Intuitivamente, un tempo di arresto è una regola per decidere quando interrompere l'osservazione di un processo casuale, basata esclusivamente sulle informazioni accumulate fino a quel momento. Le informazioni disponibili al tempo t vengono rappresentate dalla σ -algebra $\mathcal{F}_t$. Se Z è una variabile aleatoria, o più in generale un vettore di variabili aleatorie, $\sigma(Z)$ indica la più piccola σ -algebra rispetto alla quale Z è misurabile; intuitivamente, i suoi eventi sono quelli che possono essere determinati conoscendo il valore di Z . Col passare del tempo le informazioni disponibili aumentano, quindi $\mathcal{F}_t \subset \mathcal{F}_{t+1}$ per ogni t . Inoltre affinché $(\mathcal{F}_t)_{t \in \mathbb{N}}$ rappresenti le informazioni della catena (X_t) , $\mathcal{F}_t$ deve contenere il valore dello stato attuale X_t .

Formalmente, sia $(\mathcal{F}_t)_{t \in \mathbb{N}}$ una *filtrazione*, ovvero una sequenza di σ -algebre tali che $\mathcal{F}_t \subset \mathcal{F}_{t+1}$. Diciamo che (X_t) è *adattata* a $(\mathcal{F}_t)$ se X_t è $\mathcal{F}_t$ -misurabile per ogni t . La filtrazione data da $\mathcal{H}_t = \sigma(X_0, X_1, \dots, X_t)$ è detta *filtrazione naturale*. Essa rappresenta quindi l'informazione ottenuta osservando la catena fino al tempo t , mentre $\sigma(X_t)$ contiene soltanto l'informazione sullo stato al tempo t . Chiaramente (X_t) è adattata alla filtrazione naturale.

È possibile riformulare la proprietà di Markov della Definizione 1.1.1 in termini di filtrazioni, usando la Definizione di speranza condizionale 1.3.1.

Definizione 3.2.2. Sia (X_t) una catena di Markov a valori nell'insieme $\mathcal{X}$, adattata alla filtrazione $(\mathcal{F}_t)$. Diciamo che (X_t) soddisfa la *proprietà di Markov rispetto a $(\mathcal{F}_t)$* se per ogni $t \geq 0$ e per ogni $y \in \mathcal{X}$

$$(3.2.1) \quad \mathbf{E} [\mathbf{1}_{\{X_{t+1}=y\}} \mid \mathcal{F}_t] = \mathbf{E} [\mathbf{1}_{\{X_{t+1}=y\}} \mid \sigma(X_t)] .$$

Quando $\mathcal{F}_t$ è la filtrazione naturale, questa condizione coincide con la proprietà di Markov introdotta nella Definizione 1.1.1: condizionare rispetto a tutto il passato $(X_0, \dots, X_t)$ dà la stessa distribuzione del passo successivo che si ottiene condizionando soltanto rispetto allo stato presente X_t .

Possiamo quindi dare la definizione formale di tempo d'arresto.

Definizione 3.2.3. Sia (X_t) una catena di Markov adattata alla filtrazione $(\mathcal{F}_t)$. Un tempo d'arresto per la catena (X_t) è una variabile aleatoria τ a valori in $\mathbb{N} \cup \{\infty\}$ tale che $\{\tau = t\} \in \mathcal{F}_t$.

Se la filtrazione di un tempo d'arresto non è specificata, si tratta della filtrazione naturale.

3.2.2 Stationary Times

Se mescoliamo un mazzo di n carte come nell'Esempio 3.2.1, inserendo a ogni passo la carta che si trova in cima in una posizione casuale del mazzo, al passo successivo

rispetto a quando la carta originariamente in fondo arriva per la prima volta in cima al mazzo, il mazzo è perfettamente mescolato. Questo è un esempio di *stationary time*, di cui segue la definizione.

Fissiamo uno stato iniziale $x \in \mathcal{X}$ della catena (X_t) .

Definizione 3.2.4. Sia (X_t) una catena di Markov irriducibile adattata alla filtrazione $(\mathcal{F}_t)$, con distribuzione stazionaria π . Uno stationary time τ per la catena (X_t) è un tempo d'arresto rispetto a $(\mathcal{F}_t)$ tale che la distribuzione di X_τ sia π :

$$(3.2.2) \quad \mathbf{P}_x(X_\tau = y) = \pi(y) \quad \text{per ogni } y.$$

Chiediamo inoltre che $\mathbf{P}_x(\tau < \infty) = 1$, perché altrimenti X_τ non è definito.

Esempio 3.2.5. Sia (X_t) la catena di Markov con spazio degli stati $\mathcal{X} = \{0, 1\}$ che parte da 0 e che a ogni passo cambia stato: $P(0, 1) = P(1, 0) = 1$. La distribuzione stazionaria soddisfa $\pi(0) = \pi(1) = \frac{1}{2}$. Sia U una variabile aleatoria di Bernoulli di parametro $\frac{1}{2}$ e poniamo $\tau = U$. Consideriamo la filtrazione

$$\mathcal{F}_t = \sigma(X_0, \dots, X_t, U).$$

Allora τ è un tempo d'arresto rispetto a $(\mathcal{F}_t)$. Inoltre

$$\mathbf{P}(X_\tau = 0) = \mathbf{P}(\tau = 0) = \frac{1}{2}, \quad \mathbf{P}(X_\tau = 1) = \mathbf{P}(\tau = 1) = \frac{1}{2},$$

quindi τ è uno stationary time. Tuttavia τ e X_τ non sono indipendenti: se $\tau = 0$, allora $X_\tau = 0$, mentre se $\tau = 1$, allora $X_\tau = 1$.

3.2.3 Strong Stationary Times

Sia (X_t) una catena di Markov irriducibile adattata alla filtrazione $(\mathcal{F}_t)$, con distribuzione stazionaria π . Uno **strong stationary time** per la catena (X_t) , con stato iniziale x , è un tempo d'arresto rispetto a $(\mathcal{F}_t)$ tale che per ogni tempo t e per ogni stato y si abbia

$$\mathbf{P}_x(\tau = t, X_\tau = y) = \mathbf{P}_x\{\tau = t\}\pi(y),$$

e tale che $\mathbf{P}_x(\tau < \infty) = 1$. Equivalentemente, τ è uno stationary time e le variabili aleatorie τ e X_τ sono indipendenti.

Come detto, vogliamo usare gli strong stationary times per stimare dall'alto t_{mix} . Per farlo, useremo la seguente proposizione.

Proposizione 3.2.6. Sia (X_t) una catena di Markov con distribuzione iniziale δ_x e distribuzione stazionaria π , e sia τ uno strong stationary time per la catena (X_t) . Allora vale

$$(3.2.3) \quad \|P^t(x, \cdot) - \pi\|_{\text{TV}} \leq \mathbf{P}_x(\tau > t).$$

Dimostrazione. Dimostriamo prima che vale la seguente uguaglianza:

$$(3.2.4) \quad \mathbf{P}_x(\tau \leq t, X_t = y) = \mathbf{P}_x(\tau \leq t)\pi(y).$$

Intuitivamente, questo segue dal fatto che una volta che lo strong stationary time è stato raggiunto, da quel momento in poi la distribuzione rimarrà quella stazionaria. Quindi $\mathbf{P}_x(\tau \leq t, X_t = y) = \mathbf{P}_x(X_t = y \mid \tau \leq t)\mathbf{P}_x(\tau \leq t) = \mathbf{P}_x(\tau \leq t)\pi(y)$. È proprio nel dimostrare questa uguaglianza che si usa sia il fatto che τ sia un tempo d'arresto, sia l'indipendenza di τ e X_τ , ovvero il fatto che τ sia uno strong stationary time e non solo uno stationary time.

La dimostrazione formale è la seguente: abbiamo

$$\begin{aligned} \mathbf{P}_x\{\tau \leq t, X_t = y\} &= \sum_{s \leq t} \sum_z \mathbf{P}_x\{\tau = s, X_s = z, X_t = y\} \\ &= \sum_{s \leq t} \sum_z \mathbf{P}_x\{X_t = y \mid \tau = s, X_s = z\} \mathbf{P}_x\{\tau = s, X_s = z\}. \end{aligned}$$

Poiché τ è un tempo d'arresto, l'evento $\{\tau = s\}$ appartiene a $\mathcal{F}_s$. Usando la proprietà di Markov, possiamo riscrivere l'espressione precedente come

$$\sum_{s \leq t} \sum_z P^{t-s}(z, y) \mathbf{P}_x\{\tau = s, X_s = z\}.$$

Dato che le variabili τ e X_τ sono indipendenti e $X_\tau \sim \pi$, otteniamo che tale somma vale

$$\sum_{s \leq t} \sum_z P^{t-s}(z, y) \mathbf{P}_x\{\tau = s\} \pi(z).$$

Dal fatto che π sia la distribuzione stazionaria segue che $\sum_z \pi(z) P^{t-s}(z, y) = \pi(y)$, quindi per ogni $t \geq 0$ e per ogni y vale

$$\mathbf{P}_x\{\tau \leq t, X_t = y\} = \mathbf{P}_x\{\tau \leq t\}\pi(y).$$

Dato un sottoinsieme A di $\mathcal{X}$, dall'uguaglianza (3.2.4) si ottiene, sommando al variare di $y \in A$,

$$\mathbf{P}_x(\tau \leq t, X_t \in A) = \mathbf{P}_x(\tau \leq t)\pi(A).$$

A questo punto possiamo stimare direttamente la differenza tra le quantità $\mathbf{P}_x(X_t \in A)$ e $\pi(A)$:

$$\begin{aligned} \mathbf{P}_x(X_t \in A) &= \mathbf{P}_x(X_t \in A, \tau \leq t) + \mathbf{P}_x(X_t \in A, \tau > t) \\ &= \pi(A)\mathbf{P}_x(\tau \leq t) + \mathbf{P}_x(X_t \in A \mid \tau > t)\mathbf{P}_x(\tau > t). \end{aligned}$$

Sostituendo $\mathbf{P}_x(\tau \leq t) = 1 - \mathbf{P}_x(\tau > t)$, otteniamo:

$$\mathbf{P}_x(X_t \in A) = \pi(A) + [\mathbf{P}_x(X_t \in A \mid \tau > t) - \pi(A)]\mathbf{P}_x(\tau > t).$$

Quindi

$$|\mathbf{P}_x(X_t \in A) - \pi(A)| = |\mathbf{P}_x(X_t \in A \mid \tau > t) - \pi(A)|\mathbf{P}_x(\tau > t) \leq \mathbf{P}_x(\tau > t),$$

dato che il termine $|\mathbf{P}_x(X_t \in A \mid \tau > t) - \pi(A)|$, essendo la differenza di due probabilità, è minore o uguale a 1. La tesi segue dalla definizione di distanza in variazione totale. $\square$

Il seguente lemma ci permette di verificare che una variabile aleatoria τ sia uno strong stationary time condizionando sull'evento $\{\tau \leq t\}$ invece che sull'evento $\{\tau = t\}$.

Lemma 3.2.7. Sia x uno stato della catena (X_t) . Se τ è un tempo d'arresto con $\mathbf{P}_x(\tau < \infty) = 1$ e per ogni tempo t e stato y vale

$$\mathbf{P}_x(X_t = y \mid \tau \leq t) = \pi(y),$$

allora τ è uno strong stationary time per lo stato iniziale x .

Dimostrazione. Per ogni y si ha

$$\mathbf{P}_x(X_t = y, \tau = t) = \mathbf{P}_x(X_t = y, \tau \leq t) - \mathbf{P}_x(X_t = y, \tau \leq t - 1).$$

Dall'ipotesi segue che $\mathbf{P}_x(X_t = y, \tau \leq t) = \mathbf{P}_x(\tau \leq t)\pi(y)$. Per il secondo termine, dato che τ è un tempo d'arresto, l'evento $\{\tau \leq t - 1\}$ appartiene a $\mathcal{F}_{t-1}$. Quindi, usando la proprietà di Markov,

$$\begin{aligned} \mathbf{P}_x(X_t = y, \tau \leq t - 1) &= \sum_z \mathbf{P}_x(X_{t-1} = z, \tau \leq t - 1)P(z, y) \\ &= \mathbf{P}_x(\tau \leq t - 1) \sum_z \pi(z)P(z, y) \\ &= \mathbf{P}_x(\tau \leq t - 1)\pi(y), \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato la stazionarietà di π . Quindi

$$\mathbf{P}_x(X_t = y, \tau = t) = \pi(y)(\mathbf{P}_x(\tau \leq t) - \mathbf{P}_x(\tau \leq t - 1)) = \pi(y)\mathbf{P}_x(\tau = t),$$

che è la definizione di strong stationary time. $\square$

3.2.4 Esempi di applicazione

Vediamo adesso come sia possibile usare la Proposizione 3.2.6 per stimare dall'alto il mixing time di alcune passeggiate aleatorie su gruppi. In questo capitolo e nel Capitolo 5, analizzeremo alcuni modi di mescolare un mazzo di n carte, che corrispondono a passeggiate aleatorie sul gruppo simmetrico S_n . Come nell'esempio introduttivo, mostreremo per ogni tempo t che l'ordine relativo delle carte appartenenti a un certo insieme aleatorio C_t è uniforme. Lo strong stationary time corrisponderà al primo istante in cui $C_t = [n]$, dove con $[n]$ indichiamo l'insieme $\{1, 2, \dots, n\}$.

Riprendiamo adesso l'Esempio introduttivo 3.2.1. Sia (π_t) la passeggiata aleatoria su S_n data dal top to random shuffle, e sia F la carta che inizialmente si trova in fondo. Sia $S_t \in [n]$ la posizione, contata dal basso, in cui viene inserita la carta che al tempo $t - 1$ si trova in cima, ovvero la posizione scelta nella mossa che porta da π_{t-1} a π_t . Le variabili aleatorie S_t sono indipendenti e uniformi su $[n]$. Poniamo inoltre $T_0 = 0$ e

$$T_k = \inf\{t > T_{k-1} : S_t \leq k\};$$

ovvero T_k è il primo istante in cui ci sono k carte sotto F . Quindi T_{n-1} è il primo istante in cui la carta F è arrivata in cima al mazzo, e vogliamo dimostrare che $\tau := T_{n-1} + 1$ è uno strong stationary time per la catena.

Sia C_t l'insieme delle carte che, al tempo t , si trovano sotto F . Dimostriamo per induzione su t che, fino al tempo T_{n-1} , l'ordine relativo delle carte in C_t è uniforme. Per ottenere l'uniformità di π_τ condizionatamente al valore di τ dobbiamo in realtà dimostrare una proprietà leggermente più forte: anche condizionando rispetto ai tempi $T_1, \dots, T_{n-1}$ in cui le carte vengono inserite sotto la carta F , l'ordine delle carte in C_t è uniforme. Fissiamo quindi i valori di $T_1, \dots, T_{n-1}$.

Per $t = 0$ l'insieme C_0 è vuoto, quindi l'affermazione è banale. Supponiamo che l'affermazione valga al tempo $t < T_{n-1}$. Al passo successivo ci sono due possibilità. Se la carta in cima non viene inserita sotto F , allora l'insieme C_t non cambia e l'ordine relativo delle carte sotto F rimane lo stesso, quindi la distribuzione resta uniforme.

Se invece la carta in cima viene inserita sotto F , allora una nuova carta si aggiunge a C_t . Supponiamo che $|C_t| = k$. Condizionatamente al fatto che la nuova carta venga inserita sotto F , ovvero al fatto che $t + 1 = T_{k+1}$, la variabile S_{t+1} è uniformemente distribuita su $[k + 1]$. Dato che l'ordine relativo delle carte in C_t è uniforme, ciascuna delle $(k + 1)!$ permutazioni delle carte in C_{t+1} è equiprobabile.

Al tempo T_{n-1} , la carta F si trova per la prima volta in cima al mazzo e l'ordine relativo delle $n - 1$ carte che si trovano sotto di essa è uniforme. Al tempo $\tau = T_{n-1} + 1$ la carta F viene inserita in una posizione uniforme e indipendente dal passato, e quindi tutte le $n!$ permutazioni delle carte sono equiprobabili. Dunque l'ordine delle carte al tempo τ è uniforme anche condizionatamente ai valori di $T_1, \dots, T_{n-1}$, e in particolare anche condizionatamente al valore di $\tau = T_{n-1} + 1$. Questo dimostra che τ è uno strong stationary time.

Vogliamo adesso studiare la distribuzione della variabile aleatoria τ per usare la Proposizione 3.2.6. In questo e in altri esempi che esamineremo ciò si riconduce al classico *problema del collezionista*, che descriviamo di seguito basandoci su [LP17, Capitolo 2].

Un'azienda produce n tipi diversi di figurine. Un collezionista desidera ottenere ciascun tipo di figurina. Supponiamo che ogni figurina che acquista sia uniformemente distribuita tra gli n possibili tipi e indipendente da quelle già acquisite. Quante figurine deve acquistare il collezionista affinché la sua collezione contenga tutti gli n tipi?

Questo processo può essere descritto nel linguaggio delle catene di Markov. Sia X_t il numero di tipi diversi di figurine che compaiono nelle prime t figurine acquistate. Chiaramente $X_0 = 0$ e, quando il collezionista ha k diversi tipi di figurine, solo le

figurine dei restanti $n - k$ tipi espandono la sua collezione. Quindi

$$\mathbf{P}(X_{t+1} = k + 1 \mid X_t = k) = \frac{n - k}{n},$$

e

$$\mathbf{P}(X_{t+1} = k \mid X_t = k) = \frac{k}{n}.$$

Proposizione 3.2.8. Sia $\tau_n = \min\{t \mid X_t = n\}$ il minimo numero di figurine da acquistare per completare la collezione. Allora

$$\mathbf{E}(\tau_n) = n \sum_{k=1}^n \frac{1}{k} = n \log n + \mathcal{O}(n);$$

inoltre

$$\text{Var}(\tau_n) = \mathcal{O}(n^2).$$

Dimostrazione. Sia $\tau_n^{(k)} = \min\{t \mid X_t = k\}$ il minimo numero di figurine da acquistare per avere k tipi diversi di figurine, e poniamo $\tau_n^{(0)} = 0$. Allora

$$\tau_n = \sum_{k=1}^n \left(\tau_n^{(k)} - \tau_n^{(k-1)} \right).$$

Le variabili aleatorie $\tau_n^{(k)} - \tau_n^{(k-1)}$ sono indipendenti e hanno distribuzione geometrica con probabilità di successo $\frac{n-k+1}{n}$: quando nella collezione sono presenti $k - 1$ tipi diversi di figurine, quelli mancanti sono $n - k + 1$. Otteniamo quindi

$$\mathbf{E}(\tau_n) = \sum_{k=1}^n \frac{n}{n - k + 1} = n \sum_{k=1}^n \frac{1}{k}.$$

Dal fatto che

$$\sum_{j=1}^n \frac{1}{j} = \log n + \mathcal{O}(1)$$

si ottiene

$$n \sum_{k=1}^n \frac{1}{k} = n \log n + \mathcal{O}(n).$$

Ricordiamo che, data una variabile aleatoria geometrica X di parametro p , vale

$$\text{Var}(X) = \frac{1 - p}{p^2} \leq \frac{1}{p^2}.$$

Usando l'indipendenza delle variabili $\tau_n^{(k)} - \tau_n^{(k-1)}$, otteniamo

$$\begin{aligned} \text{Var}(\tau_n) &= \sum_{k=1}^n \text{Var} \left(\tau_n^{(k)} - \tau_n^{(k-1)} \right) \\ &\leq \sum_{k=1}^n \frac{n^2}{(n - k + 1)^2} = n^2 \sum_{j=1}^n \frac{1}{j^2} \leq n^2 \sum_{j=1}^{\infty} \frac{1}{j^2} = \mathcal{O}(n^2). \end{aligned}$$

□

La seguente proposizione afferma che è improbabile che τ_n si discosti molto dal suo valore atteso.

Proposizione 3.2.9. Sia τ_n definita come nella Proposizione 3.2.8. Per ogni $\alpha > 0$,

$$(3.2.5) \quad \mathbf{P}(\tau_n > \lceil n \log n + \alpha n \rceil) \leq e^{-\alpha}.$$

Dimostrazione. Sia A_i l'evento: l' i -esimo tipo di figurina non appare nelle prime $\lceil n \log n + \alpha n \rceil$ figurine acquistate. Notiamo che

$$\mathbf{P}\{\tau_n > \lceil n \log n + \alpha n \rceil\} = \mathbf{P}\left(\bigcup_{i=1}^n A_i\right) \leq \sum_{i=1}^n \mathbf{P}(A_i).$$

Ciascuna delle figurine acquistate ha probabilità $1 - \frac{1}{n}$ di non essere di tipo i ed è indipendente dalle altre, quindi

$$\sum_{i=1}^n \mathbf{P}(A_i) = \sum_{i=1}^n \left(1 - \frac{1}{n}\right)^{\lceil n \log n + \alpha n \rceil} \leq n \exp\left(-\frac{n \log n + \alpha n}{n}\right) = e^{-\alpha},$$

che dimostra (3.2.5). □

Torniamo ora allo strong stationary time $\tau = T_{n-1} + 1$ costruito per il top to random shuffle. Ricordiamo che T_k è il primo istante in cui ci sono k carte sotto F . Quando ci sono $k - 1$ carte sotto F , la probabilità che venga inserita una nuova carta sotto F è pari a $\frac{k}{n}$, quindi $T_k - T_{k-1}$ ha distribuzione geometrica di parametro $\frac{k}{n}$. Dunque

$$\tau = 1 + \sum_{k=1}^{n-1} (T_k - T_{k-1})$$

ha la stessa distribuzione del tempo necessario per completare una collezione di n figurine. Applicando la Proposizione 3.2.9, otteniamo che, per ogni $\alpha > 0$,

$$\mathbf{P}(\tau > \lceil n \log n + \alpha n \rceil) \leq e^{-\alpha}.$$

Poiché τ è uno strong stationary time, dalla Proposizione 3.2.6 segue che

$$d(\lceil n \log n + \alpha n \rceil) \leq e^{-\alpha}.$$

Ponendo $\alpha = \log(\varepsilon^{-1})$ si ottiene

$$t_{\text{mix}}(\varepsilon) \leq n \log n + n \log(\varepsilon^{-1}).$$

Vediamo adesso una stima dal basso dello stesso ordine, seguendo un argomento di Aldous e Diaconis [AD86].

Proposizione 3.2.10. Sia (π_t) la catena data dal top to random shuffle per un mazzo da n carte, e indichiamo con $d_n(t)$ la distanza dalla stazionarietà. Per ogni $\varepsilon > 0$, esiste una costante $\alpha(\varepsilon)$ tale che per $\alpha > \alpha(\varepsilon)$ e per n sufficientemente grande si abbia

$$d_n(\lfloor n \log n - \alpha n \rfloor) \geq 1 - \varepsilon,$$

o equivalentemente

$$t_{\text{mix}}(1 - \varepsilon) \geq n \log n - \alpha n.$$

Dimostrazione. L'idea è di considerare l'evento

$$A_j = \{ \text{le } j \text{ carte inizialmente in fondo al mazzo} \\ \text{compaiono ancora nel loro ordine relativo iniziale} \}$$

e sfruttare il fatto che $d_n(t) \geq P^t(\text{id}, A_j) - U(A_j)$. È chiaro che $U(A_j) = 1/j!$, mentre per stimare dal basso $P^t(\text{id}, A_j)$ notiamo che, finché la j -esima carta a partire dal fondo del mazzo non ha raggiunto la cima ed è stata reinserita, A_j è sicuramente verificato. Il tempo necessario affinché ciò avvenga ha la stessa distribuzione del tempo necessario per passare da $j - 1$ carte sotto F al momento in cui F viene reinserita nel mazzo, ovvero della variabile aleatoria $\tau - T_{j-1}$. Quindi

$$P^t(\text{id}, A_j) \geq \mathbf{P}(\tau - T_{j-1} > t).$$

Fissiamo ora $\varepsilon > 0$ e scegliamo j abbastanza grande da avere $1/j! < \varepsilon/2$. Procedendo come nel problema del collezionista, per j fissato si ha

$$\mathbf{E}(\tau - T_{j-1}) = \sum_{k=j}^n \frac{n}{k} = n \log n + \mathcal{O}(n),$$

$$\text{Var}(\tau - T_{j-1}) = \sum_{k=j}^n \frac{n^2}{k^2} \left(1 - \frac{k}{n}\right) = \mathcal{O}(n^2).$$

Poniamo $X = \tau - T_{j-1}$ e $t_n(\alpha) = \lfloor n \log n - \alpha n \rfloor$. Notiamo che la quantità $\mathbf{E}(X) - t_n(\alpha) = \alpha n + \mathcal{O}(n)$ è positiva per α sufficientemente grande.

Applicando la disuguaglianza di Chebyshev otteniamo

$$\begin{aligned} \mathbf{P}(X \leq t_n(\alpha)) &\leq \mathbf{P}(|X - \mathbf{E}(X)| \geq \mathbf{E}(X) - t_n(\alpha)) \\ &\leq \frac{\text{Var}(X)}{(\mathbf{E}(X) - t_n(\alpha))^2} \\ &= \frac{\mathcal{O}(n^2)}{(\alpha n + \mathcal{O}(n))^2} = \mathcal{O}\left(\frac{1}{\alpha^2}\right), \end{aligned}$$

ovvero la quantità $\mathbf{P}(X \leq t_n(\alpha))$ tende a 0 per $\alpha \rightarrow \infty$. Scegliamo $\alpha(\varepsilon)$ abbastanza grande in modo che, per ogni $\alpha > \alpha(\varepsilon)$, valga $\mathbf{P}(X \leq t_n(\alpha)) \leq \varepsilon/2$. Per $\alpha > \alpha(\varepsilon)$ e per n sufficientemente grande,

$$P^{t_n(\alpha)}(\text{id}, A_j) \geq \mathbf{P}(\tau - T_{j-1} > t_n(\alpha)) \geq 1 - \frac{\varepsilon}{2},$$

e quindi

$$d_n(t_n(\alpha)) \geq P^{t_n(\alpha)}(\text{id}, A_j) - U(A_j) \geq 1 - \frac{\varepsilon}{2} - \frac{1}{j!} \geq 1 - \varepsilon.$$

□

Esempio 3.2.11 (Passeggiata aleatoria lazy sull'ipercubo n -dimensionale). Sia $G = \mathbb{Z}_2^n$ l'ipercubo n -dimensionale e denotiamo con e_i l' i -esimo vettore della base canonica, con componenti date da $(e_i)_j = \delta_{ij}$. Consideriamo la passeggiata aleatoria su G con transizioni date da

$$\mu(g) = \begin{cases} \frac{1}{n}, & \text{se } g \in \{e_1, e_2, \dots, e_n\}; \\ 0, & \text{altrimenti.} \end{cases}$$

In altre parole, a ogni passo scegliamo una coordinata $j \in [n]$ in maniera uniforme, e la cambiamo.




Figura 3.2.2: L'ipercubo tridimensionale.

Questa passeggiata aleatoria è periodica, dato che la parità del tempo t determina la parità del numero di 1 presenti nella rappresentazione di X_t . Consideriamo quindi la versione lazy della catena, che con probabilità $\frac{1}{2}$ rimane nello stato corrente e con probabilità $\frac{1}{2}$ si muove nel modo descritto precedentemente. Un passo della catena lazy corrisponde a scegliere un elemento (j, B) da $[n] \times \{0, 1\}$ in maniera uniforme, e sostituire la coordinata j dello stato corrente con il valore B : con probabilità $\frac{1}{2}$, B coincide con il valore corrente e la catena resta ferma, e con probabilità $\frac{1}{2}$ la coordinata j viene cambiata.

L'idea dietro alla costruzione dello strong stationary time è che, una volta che tutte le coordinate sono state selezionate almeno una volta, ciascuna coordinata è indipendente e uniformemente distribuita su $\{0, 1\}$, e quindi la distribuzione della catena è uniforme. L'indipendenza segue dal fatto che τ dipende solo dalla sequenza delle coordinate scelte, mentre il valore finale di X_τ dipende dai valori assegnati all'ultima visita di ciascuna coordinata, che sono indipendenti dalle coordinate scelte.

Formalmente, sia $(Z_t) = (j_t, B_t)$ la sequenza di variabili aleatorie indipendenti e distribuite uniformemente su $[n] \times \{0, 1\}$ che determina l'evoluzione della catena: si

aggiorna la coordinata j_t di X_{t-1} con il valore B_t per ottenere X_t . Poniamo

$$\tau := \min\{t \geq 0 : \{j_1, \dots, j_t\} = [n]\}.$$

La variabile aleatoria τ non è un tempo d'arresto per la filtrazione naturale. Tuttavia, è un tempo d'arresto per la filtrazione data da $\mathcal{F}_t = \sigma(X_0, Z_1, \dots, Z_t)$. Poniamo

$$T_i = \max\{t \leq \tau \mid j_t = i\}, \quad \text{per ogni } i \in [n];$$

ovvero l'ultimo istante in cui è stata scelta la coordinata i . Condizioniamo ora sulla sequenza delle coordinate scelte $j_1, j_2, \dots$, che determinano i valori di τ e di $T_1, \dots, T_n$. Dato che le variabili B_t sono indipendenti tra loro e indipendenti dalle coordinate scelte, le variabili $B_{T_1}, \dots, B_{T_n}$ sono indipendenti e uniformemente distribuite su $\{0, 1\}$. Quindi il vettore

$$X_\tau = (B_{T_1}, \dots, B_{T_n})$$

è uniformemente distribuito su $\{0, 1\}^n$. Poiché questa conclusione vale per ogni possibile sequenza delle coordinate scelte, vale anche condizionando soltanto sul valore di τ . Dunque, per ogni t e per ogni $x \in \{0, 1\}^n$,

$$\mathbf{P}(X_\tau = x \mid \tau = t) = 2^{-n},$$

ovvero τ è uno strong stationary time.

È chiaro che la variabile aleatoria τ ha la stessa distribuzione della variabile aleatoria τ_n del problema del collezionista, definita nella Proposizione 3.2.8. Quindi dalle Proposizioni 3.2.9 e 3.2.6 segue che

$$d(\lceil n \log n + cn \rceil) \leq \mathbf{P}(\tau > \lceil n \log n + cn \rceil) \leq e^{-c},$$

dunque

$$t_{\text{mix}}(\varepsilon) \leq n \log n + n \log(\varepsilon^{-1}).$$

Abbiamo visto come il metodo dello strong stationary time permetta di trovare soluzioni molto eleganti a problemi di mixing. Si tratta però di una tecnica che richiede che la catena che studiamo presenti numerose simmetrie, come nel caso delle passeggiate aleatorie su gruppi. Inoltre non è molto versatile: ogni problema richiede un'idea specifica. Nella prossima sezione, esaminiamo una tecnica che si applica in contesti più ampi, basata sullo studio della geometria dello spazio degli stati e dell'operatore P .

3.3 Metodi spettrali

In questa sezione esploriamo la connessione tra gli autovalori della matrice di transizione di una catena e il suo mixing time, e poi trattiamo alcune tecniche che permettono di stimare tali autovalori. Seguiremo in gran parte la trattazione di [LP17, Capitoli 12–13].

3.3.1 Autovalori

Data una matrice P , una funzione non nulla f definita su $\mathcal{X}$ è detta autofunzione con autovalore λ se $Pf = \lambda f$.

Iniziamo enunciando alcuni fatti generali sugli autovalori delle matrici di transizione.

Teorema 3.3.1. Sia P la matrice di transizione di una catena di Markov a stati finiti.

1. Se λ è un autovalore di P , allora $|\lambda| \leq 1$.
2. Se P è irriducibile, l'autospazio relativo all'autovalore 1 è generato dal vettore $\mathbf{1} := (1, 1, \dots, 1)^T$.
3. Se P è irriducibile e aperiodica, allora -1 non è un autovalore di P .

Questo risultato è enunciato in [LP17, Lemma 12.1]; una dimostrazione si trova nella soluzione dell'Esercizio 12.1, nell'Appendice D dello stesso testo.

L'analisi spettrale delle matrici di transizione diventa particolarmente utile nel caso delle catene reversibili. Ricordiamo che una catena con matrice di transizione P e distribuzione stazionaria π è detta *reversibile* se per ogni $x, y \in \mathcal{X}$ vale $\pi(x)P(x, y) = \pi(y)P(y, x)$ (come nella Definizione 1.1.7).

Data una catena con distribuzione stazionaria π , introduciamo il prodotto scalare su $\mathbb{R}^{\mathcal{X}}$ dato da

$$\langle f, g \rangle_{\pi} := \sum_{x \in \mathcal{X}} f(x)g(x)\pi(x).$$

Il motivo dietro l'introduzione di questo prodotto scalare è il seguente:

Proposizione 3.3.2. Sia P la matrice di transizione di una catena reversibile con distribuzione stazionaria π . Allora P è autoaggiunta rispetto a $\langle \cdot, \cdot \rangle_{\pi}$.

Dimostrazione. Siano f, g due funzioni definite su $\mathcal{X}$.

$$\begin{aligned} \langle f, Pg \rangle_{\pi} &= \sum_{x \in \mathcal{X}} f(x)(Pg)(x)\pi(x) \\ &= \sum_{x, y \in \mathcal{X}} f(x)g(y)P(x, y)\pi(x) \\ &= \sum_{x, y \in \mathcal{X}} f(x)g(y)P(y, x)\pi(y) \\ &= \sum_{y \in \mathcal{X}} (Pf)(y)g(y)\pi(y) \\ &= \langle Pf, g \rangle_{\pi}. \end{aligned}$$

□

Otteniamo quindi i seguenti risultati:

Proposizione 3.3.3. Sia P irriducibile e reversibile rispetto a π . Allora

1. Lo spazio vettoriale $(\mathbb{R}^{\mathcal{X}}, \langle \cdot, \cdot \rangle_\pi)$ ha una base ortonormale di autofunzioni reali $\{f_j\}_{j=1}^{|\mathcal{X}|}$ corrispondenti ad autovalori reali $\{\lambda_j\}$.
2. Vale l'identità

$$(3.3.1) \quad \frac{P^t(x, y)}{\pi(y)} = \sum_{j=1}^{|\mathcal{X}|} f_j(x) f_j(y) \lambda_j^t.$$

3. L'autofunzione f_1 corrispondente all'autovalore 1 può essere scelta come il vettore costante $\mathbf{1}$, ottenendo

$$(3.3.2) \quad \frac{P^t(x, y)}{\pi(y)} = 1 + \sum_{j=2}^{|\mathcal{X}|} f_j(x) f_j(y) \lambda_j^t.$$

Dimostrazione. 1. Segue dalla Proposizione 3.3.2 e dal teorema spettrale.

2. Sia δ_y la funzione

$$\delta_y(x) = \begin{cases} 1 & \text{se } y = x, \\ 0 & \text{se } y \neq x. \end{cases}$$

Notiamo che $P^t(x, y) = (P^t \delta_y)(x)$. Scriviamo quindi δ_y nella base di autovettori:

$$\delta_y = \sum_{j=1}^{|\mathcal{X}|} \langle \delta_y, f_j \rangle_\pi f_j = \sum_{j=1}^{|\mathcal{X}|} f_j(y) \pi(y) f_j.$$

Dato che $P^t f_j = \lambda_j^t f_j$ otteniamo

$$P^t(x, y) = \sum_{j=1}^{|\mathcal{X}|} f_j(y) \pi(y) \lambda_j^t f_j(x).$$

Dividendo per $\pi(y)$ si ottiene l'espressione voluta.

3. Segue dal punto precedente dopo aver notato che $\langle \mathbf{1}, \mathbf{1} \rangle_\pi = 1$.

□

3.3.2 Il relaxation time

Se P è irriducibile, aperiodica e reversibile, dal Teorema 3.3.1 e dall'Equazione (3.3.2) risulta chiaro che la quantità $\frac{P^t(x, y)}{\pi(y)} - 1$ decade a 0 esponenzialmente, e che il termine dominante dipende dall'autovalore diverso da 1 di massimo modulo. Introduciamo quindi le seguenti definizioni.

Definizione 3.3.4. Sia P una matrice di transizione e sia

$$\lambda_\star := \max\{|\lambda| : \lambda \text{ è un autovalore di } P, \lambda \neq 1\}.$$

Definiamo *gap spettrale assoluto* la quantità $\gamma_\star := 1 - \lambda_\star$.

Il Teorema 3.3.1 implica che se P è irriducibile e aperiodica, si ha $\gamma_\star > 0$.

La scala temporale caratteristica del sistema è detta *relaxation time*, ed è definita come

$$t_{\text{rel}} := \frac{1}{\gamma_\star}.$$

Se P è reversibile e irriducibile, per la Proposizione 3.3.3 tutti i suoi autovalori sono reali e li possiamo ordinare in modo debolmente decrescente:

$$(3.3.3) \quad 1 = \lambda_1 > \lambda_2 \geq \dots \geq \lambda_{|\mathcal{X}|} \geq -1.$$

Notiamo che in questo caso $\lambda_\star = \max(\lambda_2, |\lambda_{|\mathcal{X}|}|)$. Il caso in cui $\lambda_2 \approx 1$ corrisponde a un collo di bottiglia geometrico, mentre il caso in cui $\lambda_{|\mathcal{X}|} \approx -1$ corrisponde a una catena molto vicina all'essere periodica. Per differenziare questi due casi, introduciamo anche la seguente definizione.

Definizione 3.3.5. Sia P la matrice di transizione di una catena reversibile e siano $\{\lambda_i\}_{i=1}^{|\mathcal{X}|}$ i suoi autovalori ordinati come sopra. Il *gap spettrale* è definito come $\gamma := 1 - \lambda_2$.

Nella versione lazy di P , costruita come $Q = \frac{P+I}{2}$, tutti gli autovalori $\{\frac{\lambda_i+1}{2}\}_{i=1}^{|\mathcal{X}|}$ sono non negativi. In questo caso quindi le quantità $\gamma_\star$ e γ coincidono.

La relazione tra mixing time e relaxation time è spiegata dai prossimi due teoremi, che forniscono una stima per il mixing time dall'alto e dal basso rispettivamente.

Teorema 3.3.6. Sia P la matrice di transizione di una catena irriducibile, aperiodica e reversibile con spazio degli stati $\mathcal{X}$, e sia $\pi_{\min} := \min_{x \in \mathcal{X}} \pi(x)$. Allora

$$(3.3.4) \quad t_{\text{mix}}(\varepsilon) \leq t_{\text{rel}} \log \left(\frac{1}{\varepsilon \pi_{\min}} \right)$$

Dimostrazione. Usando (3.3.2) e la disuguaglianza di Cauchy-Schwarz si ottiene

$$\left| \frac{P^t(x, y)}{\pi(y)} - 1 \right| \leq \sum_{j=2}^{|\mathcal{X}|} |f_j(x) f_j(y)| \lambda_\star^t \leq \lambda_\star^t \left[\sum_{j=2}^{|\mathcal{X}|} f_j^2(x) \sum_{j=2}^{|\mathcal{X}|} f_j^2(y) \right]^{1/2}.$$

Per stimare $\sum_{j=2}^{|\mathcal{X}|} f_j^2(x)$, notiamo che

$$\pi(x) = \langle \delta_x, \delta_x \rangle_\pi = \left\langle \sum_{j=1}^{|\mathcal{X}|} f_j(x) \pi(x) f_j, \sum_{j=1}^{|\mathcal{X}|} f_j(x) \pi(x) f_j \right\rangle_\pi = \pi(x)^2 \sum_{j=1}^{|\mathcal{X}|} f_j(x)^2,$$

da cui $\sum_{j=2}^{|\mathcal{X}|} f_j^2(x) \leq \pi(x)^{-1}$. Quindi

$$\left| \frac{P^t(x, y)}{\pi(y)} - 1 \right| \leq \frac{\lambda_\star^t}{\sqrt{\pi(x)\pi(y)}} \leq \frac{\lambda_\star^t}{\pi_{\min}} = \frac{(1 - \gamma_\star)^t}{\pi_{\min}} \leq \frac{e^{-\gamma_\star t}}{\pi_{\min}}.$$

Possiamo quindi stimare dall'alto la distanza in variazione totale:

$$\|P^t(x, \cdot) - \pi\|_{TV} = \frac{1}{2} \sum_{y \in \mathcal{X}} \pi(y) \left| \frac{P^t(x, y)}{\pi(y)} - 1 \right| \leq \frac{1}{2} \sum_{y \in \mathcal{X}} \pi(y) \frac{e^{-\gamma_\star t}}{\pi_{\min}} = \frac{e^{-\gamma_\star t}}{2\pi_{\min}} \leq \frac{e^{-\gamma_\star t}}{\pi_{\min}}.$$

Imponendo $\frac{e^{-\gamma_\star t}}{\pi_{\min}} \leq \varepsilon$ si ottiene

$$t \geq \frac{1}{\gamma_\star} \log \left(\frac{1}{\varepsilon \pi_{\min}} \right) = t_{\text{rel}} \log \left(\frac{1}{\varepsilon \pi_{\min}} \right).$$

La tesi segue dalla definizione di $t_{\text{mix}}(\varepsilon)$. $\square$

Prima di dimostrare la stima dal basso, dimostriamo il seguente lemma. Data una matrice di transizione P con distribuzione stazionaria π , e una funzione f definita sullo spazio degli stati $\mathcal{X}$, denotiamo con $\mathbf{E}_\pi(f) = \pi f$ il suo valore atteso sotto la distribuzione di probabilità π .

Lemma 3.3.7. Sia P una matrice di transizione con distribuzione stazionaria π . Se f è un'autofunzione di P con autovalore $\lambda \neq 1$, allora $\mathbf{E}_\pi(f) = 0$.

Dimostrazione. Per ipotesi $Pf = \lambda f$; moltiplicando questa equazione a sinistra per π otteniamo $\pi Pf = \pi \lambda f$, ovvero $\pi f = \lambda \pi f$, da cui $\pi f = \mathbf{E}_\pi(f) = 0$. $\square$

Teorema 3.3.8. Sia $\lambda \neq 1$ un autovalore della matrice di transizione P di una catena irriducibile e aperiodica, e sia $\varepsilon \in (0, 1/2)$. Allora

$$(3.3.5) \quad t_{\text{mix}}(\varepsilon) \geq \left(\frac{1}{1 - |\lambda|} - 1 \right) \log \left(\frac{1}{2\varepsilon} \right).$$

In particolare, per catene reversibili

$$(3.3.6) \quad t_{\text{mix}}(\varepsilon) \geq (t_{\text{rel}} - 1) \log \left(\frac{1}{2\varepsilon} \right).$$

Dimostrazione. Siano λ, f tali che $Pf = \lambda f$, con $\lambda \neq 1$. Per il Teorema 3.3.1, $\lambda \neq -1$. Possiamo supporre anche $\lambda \neq 0$. Dal Lemma 3.3.7 sappiamo che $\pi f = 0$, e usiamo questo fatto per scrivere $|P^t f(x)|$ in due modi:

$$(3.3.7) \quad \begin{aligned} |\lambda^t f(x)| &= |P^t f(x)| = |P^t f(x) - \pi f| \\ &= \left| \sum_{y \in \mathcal{X}} [P^t(x, y) f(y) - \pi(y) f(y)] \right| \leq \|f\|_\infty 2d(t). \end{aligned}$$

Con questa disuguaglianza possiamo ottenere una stima dal basso per il mixing time. Sia x tale che $|f(x)| = \|f\|_\infty$. Allora (3.3.7) diventa

$$|\lambda|^t \leq 2d(t).$$

Per $t = t_{\text{mix}}(\varepsilon)$ otteniamo $|\lambda|^{t_{\text{mix}}(\varepsilon)} \leq 2\varepsilon$. Passando ai logaritmi e usando la disuguaglianza $x - 1 \geq \log(x)$, valida per ogni x reale positivo, si ottiene

$$t_{\text{mix}}(\varepsilon) \left(\frac{1}{|\lambda|} - 1 \right) \geq t_{\text{mix}}(\varepsilon) \log \left(\frac{1}{|\lambda|} \right) \geq \log \left(\frac{1}{2\varepsilon} \right).$$

Dato che $(\frac{1}{|\lambda|} - 1)^{-1} = \frac{1}{1-|\lambda|} - 1$, la (3.3.5) è dimostrata. La (3.3.6) si ottiene massimizzando la quantità $\frac{1}{1-|\lambda|} - 1$ al variare di λ autovalore diverso da 1. $\square$

Prima di passare agli esempi, enunciamo un fatto generale che permette di passare dalle autofunzioni di una catena a quelle di una sua proiezione, e viceversa.

Lemma 3.3.9. Sia (X_t) una catena di Markov su $\mathcal{X}$ con matrice di transizione P . Sia $\sim$ una relazione di equivalenza su $\mathcal{X}$ tale che la catena delle classi $[X_t]$ sia ancora una catena di Markov, con matrice di transizione $P^\#([x], [y]) = P(x, [y])$. Allora:

1. se f è un'autofunzione di P con autovalore λ ed è costante sulle classi, allora la funzione indotta sulle classi è un'autofunzione di $P^\#$ con lo stesso autovalore.
2. se g è un'autofunzione di $P^\#$ con autovalore λ , allora il suo sollevamento $x \mapsto g([x])$ è un'autofunzione di P con lo stesso autovalore;

Una dimostrazione di questo fatto si trova in [LP17, Lemma 12.9].

Esempio 3.3.10. Esaminiamo la passeggiata aleatoria simmetrica su $\mathbb{Z}_n$, descritta nell'Esempio 1.1.2. Come abbiamo già osservato, la catena è periodica per n pari, quindi consideriamo la sua versione lazy. In questo esempio e nel successivo, indicheremo con P la matrice di transizione della catena non lazy e con Q quella della versione lazy. Chiaramente, basta calcolare gli autovalori di P per ottenere quelli di Q . Invece di calcolarli tramite il polinomio caratteristico, imponendo $\det(P - \lambda I) = 0$, cerchiamo di dedurli dalla simmetria della catena.

Data $f \in \mathbb{R}^{\mathcal{X}}$, si ha $Pf(k) = (f(k-1) + f(k+1))/2$, dove gli indici sono intesi modulo n . Se definiamo gli operatori lineari S e T tramite

$$Sf(k) = f(k-1) \quad \text{per } 0 \leq k \leq n-1,$$

e

$$Tf(k) = f(k+1), \quad \text{per } 0 \leq k \leq n-1$$

possiamo riscrivere la matrice P come $P = \frac{T+S}{2}$. È chiaro che $S = T^{-1}$, quindi

$$P = \frac{T + T^{-1}}{2}.$$

L'operatore T soddisfa $T^n = \text{Id}$, da cui segue che i suoi autovalori μ_j sono le n radici dell'unità:

$$\mu_j = e^{\frac{2\pi i j}{n}} \quad \text{per } j = 0, 1, \dots, n-1.$$

Gli autovalori di P sono quindi

$$(3.3.8) \quad \lambda_j = \frac{e^{\frac{2\pi i j}{n}} + e^{-\frac{2\pi i j}{n}}}{2} = \cos\left(\frac{2\pi j}{n}\right) \quad \text{per } j = 0, 1, \dots, n-1;$$

e gli autovalori di Q sono

$$(3.3.9) \quad \lambda_j(Q) = \frac{1}{2} + \frac{1}{2} \cos\left(\frac{2\pi j}{n}\right) \quad \text{per } j = 0, 1, \dots, n-1.$$

Possiamo dunque calcolare il gap spettrale e il relaxation time: $\lambda_1(Q) = \frac{1}{2} + \frac{1}{2} \cos\left(\frac{2\pi}{n}\right) = 1 - \frac{\pi^2}{n^2} + \mathcal{O}(n^{-4})$, ovvero $\gamma_\star = \Theta(n^{-2})$ e $t_{\text{rel}} = \Theta(n^2)$. Dato che la distribuzione stazionaria è uniforme, usando la notazione del Teorema 3.3.6 abbiamo che $\pi_{\min} = \frac{1}{n}$ e quindi, per ogni $\varepsilon \in (0, 1/2)$ fissato,

$$t_{\text{mix}}(\varepsilon) = \mathcal{O}(n^2 \log n).$$

Il Teorema 3.3.8 fornisce invece una stima dal basso del mixing time:

$$(3.3.10) \quad t_{\text{mix}}(\varepsilon) = \Omega(n^2).$$

Esempio 3.3.11. Esaminiamo la passeggiata aleatoria sull'ipercubo descritta nell'Esempio 3.2.11. Indichiamo con π la distribuzione stazionaria della catena, che sappiamo essere uniforme. Adottiamo una strategia simile a quella dell'esempio precedente, riscrivendo P come una somma di operatori lineari che rispettano la simmetria del gruppo.

Sia S_i l'operatore lineare definito da

$$S_i f(x) = f(x + e_i) \quad \text{per ogni } x \in \mathbb{Z}_2^n,$$

ovvero l'operatore che cambia la i -esima coordinata dello stato x . La matrice P si riscrive come

$$P = \frac{1}{n} \sum_{i=1}^n S_i.$$

Gli operatori S_i soddisfano $S_i^2 = \text{Id}$ per ogni i , dato che cambiare due volte la stessa coordinata lascia invariato lo stato, e quindi sono diagonalizzabili con autovalori 1 e -1 .

Per trovare gli autovalori nel caso generale, partiamo dal caso $n = 1$. Lo spazio delle funzioni su $\mathbb{Z}_2$ ha la base di autofunzioni f_{+1}, f_{-1} dell'operatore S , definito da $Sf(x) = f(x + 1)$, con autovalori 1 e -1 :

$$f_{+1}(0) = 1, \quad f_{+1}(1) = 1;$$

$$f_{-1}(0) = 1, \quad f_{-1}(1) = -1.$$

Nel caso dell'ipercubo n -dimensionale, gli operatori S_i agiscono separatamente sulle singole coordinate. Cerchiamo quindi autofunzioni costruite come prodotto di funzioni di una sola coordinata. Per ogni scelta di segni $\varepsilon = (\varepsilon_1, \dots, \varepsilon_n) \in \{-1, 1\}^n$, poniamo

$$f_\varepsilon(x) = \prod_{i=1}^n f_{\varepsilon_i}(x_i), \quad x = (x_1, \dots, x_n) \in \mathbb{Z}_2^n.$$

Vediamo come agisce ciascuno degli operatori S_i sulle funzioni f_ε : se $\varepsilon_i = 1$, la funzione non cambia quando si modifica la coordinata i ; se $\varepsilon_i = -1$, la funzione cambia segno quando si modifica la coordinata i , ovvero

$$(S_i f_\varepsilon)(x) = f_\varepsilon(x + e_i) = \varepsilon_i f_\varepsilon(x).$$

Dunque f_ε è autovettore simultaneo di tutti gli operatori S_i , con autovalore ε_i rispetto a S_i . Quindi

$$P f_\varepsilon = \frac{1}{n} \sum_{i=1}^n S_i f_\varepsilon = \frac{1}{n} \sum_{i=1}^n \varepsilon_i f_\varepsilon,$$

ovvero f_ε è autofunzione di P con autovalore $\lambda_\varepsilon = \frac{1}{n} \sum_{i=1}^n \varepsilon_i$. L'insieme $\{f_\varepsilon\}_{\varepsilon \in \{-1, 1\}^n}$ è formato da 2^n vettori distinti che soddisfano

$$\langle f_\varepsilon, f_\eta \rangle_\pi = 2^{-n} \sum_{x \in \mathbb{Z}_2^n} \prod_{i=1}^n f_{\varepsilon_i}(x_i) f_{\eta_i}(x_i) = 2^{-n} \prod_{i=1}^n \sum_{x_i \in \{0, 1\}} f_{\varepsilon_i}(x_i) f_{\eta_i}(x_i) = \delta_{\varepsilon\eta},$$

e quindi forma una base ortonormale di autovettori dello spazio vettoriale $\mathbb{R}^{\mathbb{Z}_2^n}$. Se esattamente k tra gli ε_i sono uguali a -1 , allora

$$\lambda_\varepsilon = \frac{(n - k) - k}{n} = 1 - \frac{2k}{n},$$

e quindi gli autovalori di P sono

$$\lambda_k = 1 - \frac{2k}{n}, \quad k = 0, \dots, n,$$

con molteplicità $\binom{n}{k}$.

Per la versione lazy $Q = \frac{P+I}{2}$, gli autovalori diventano

$$(3.3.11) \quad \lambda_k(Q) = \frac{1 + \lambda_k}{2} = 1 - \frac{k}{n}, \quad \text{per } k = 0, \dots, n,$$

ancora con molteplicità $\binom{n}{k}$.

Il gap spettrale è dato da $\gamma = 1 - \lambda_1(Q) = 1 - (1 - \frac{1}{n}) = \frac{1}{n}$, e quindi $t_{\text{rel}} = n$. Il Teorema 3.3.6 fornisce

$$t_{\text{mix}}(\varepsilon) \leq n(-\log \varepsilon + \log(2^n)) = n^2(\log 2 - n^{-1} \log \varepsilon),$$

mentre per il Teorema 3.3.8 abbiamo che

$$t_{\text{mix}}(\varepsilon) \geq (n - 1) \log \left(\frac{1}{2\varepsilon} \right).$$

Le stime dall'alto per il mixing time che abbiamo ottenuto in questi due esempi sono peggiori di quelle che avevamo già ottenuto negli Esempi 3.1.5 e 3.2.11, utilizzando il coupling e gli strong stationary times rispettivamente. Tuttavia, la disuguaglianza che presentiamo nel prossimo paragrafo permette di ottenere stime più raffinate.

3.3.3 Stima in ℓ^2

Mostriamo adesso un modo di stimare dall'alto il mixing time tramite gli autovalori che, specialmente nel caso delle catene transitive, risulta molto utile.

Ricordiamo che data una misura di probabilità π su $\mathcal{X}$, una funzione $f : \mathcal{X} \rightarrow \mathbb{R}$ e un numero reale $p \geq 1$,

$$\|f\|_p := \left[\sum_{x \in \mathcal{X}} |f(x)|^p \pi(x) \right]^{\frac{1}{p}}.$$

Proposizione 3.3.12. Sia P una matrice di transizione reversibile e irriducibile, con distribuzione stazionaria π e con autovalori

$$1 = \lambda_1 > \lambda_2 \geq \dots \geq \lambda_{|\mathcal{X}|} \geq -1,$$

e autofunzioni corrispondenti $\{f_j\}$, ortonormali rispetto a $\langle \cdot, \cdot \rangle_\pi$. Allora

$$(3.3.12) \quad 4\|P^t(x, \cdot) - \pi\|_{\text{TV}}^2 \leq \left\| \frac{P^t(x, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2 = \sum_{j=2}^{|\mathcal{X}|} f_j(x)^2 \lambda_j^{2t}.$$

Se la catena è transitiva, allora

$$(3.3.13) \quad 4\|P^t(x, \cdot) - \pi\|_{\text{TV}}^2 \leq \left\| \frac{P^t(x, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2 = \sum_{j=2}^{|\mathcal{X}|} \lambda_j^{2t}.$$

Dimostrazione. La Proposizione 2.2.1 permette di riscrivere la distanza in variazione totale in termini della norma $\|\cdot\|_1$. Infatti

$$(3.3.14) \quad \begin{aligned} \|P^t(x, \cdot) - \pi\|_{\text{TV}} &= \frac{1}{2} \sum_{y \in \mathcal{X}} |P^t(x, y) - \pi(y)| \\ &= \frac{1}{2} \sum_{y \in \mathcal{X}} \pi(y) \left| \frac{P^t(x, y)}{\pi(y)} - 1 \right| = \frac{1}{2} \left\| \frac{P^t(x, \cdot)}{\pi(\cdot)} - 1 \right\|_1. \end{aligned}$$

Dalla disuguaglianza di Cauchy-Schwarz segue che, per ogni funzione $f : \mathcal{X} \rightarrow \mathbb{R}$, vale $\|f\|_1 \leq \|f\|_2$:

$$\begin{aligned}
\|f\|_1 &= \sum_{x \in \mathcal{X}} |f(x)| \pi(x) \\
&= \sum_{x \in \mathcal{X}} \left(|f(x)| \sqrt{\pi(x)} \right) \left(\sqrt{\pi(x)} \right) \\
(3.3.15) \quad &\leq \left(\sum_{x \in \mathcal{X}} |f(x)|^2 \pi(x) \right)^{\frac{1}{2}} \left(\sum_{x \in \mathcal{X}} \pi(x) \right)^{\frac{1}{2}} \\
&= \|f\|_2 \cdot 1 = \|f\|_2.
\end{aligned}$$

Quindi otteniamo

$$(3.3.16) \quad 4\|P^t(x, \cdot) - \pi\|_{\text{TV}}^2 = \left\| \frac{P^t(x, \cdot)}{\pi(\cdot)} - 1 \right\|_1^2 \leq \left\| \frac{P^t(x, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2.$$

A questo punto, tramite l'Equazione (3.3.2) possiamo calcolare esplicitamente il lato destro della disuguaglianza (3.3.16), ottenendo

$$(3.3.17) \quad \left\| \frac{P^t(x, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2 = \left\| \sum_{j=2}^{|\mathcal{X}|} \lambda_j^t f_j(x) f_j \right\|_2^2 = \sum_{j=2}^{|\mathcal{X}|} f_j(x)^2 \lambda_j^{2t},$$

che dimostra l'Equazione (3.3.12).

Se la catena è transitiva, il lato sinistro dell'Equazione (3.3.17) non dipende da x . Quindi, fissato $x_0 \in \mathcal{X}$, si ha

$$(3.3.18) \quad \left\| \frac{P^t(x_0, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2 = \sum_{j=2}^{|\mathcal{X}|} f_j(x)^2 \lambda_j^{2t} \quad \text{per ogni } x \in \mathcal{X}.$$

Vogliamo far comparire la quantità $\|f_j\|_2$, che sappiamo essere uguale a 1. Sommando, al variare di $x \in \mathcal{X}$, la quantità $\pi(x) \sum_{j=2}^{|\mathcal{X}|} f_j(x)^2 \lambda_j^{2t}$, otteniamo

$$(3.3.19) \quad \left\| \frac{P^t(x_0, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2 = \sum_{j=2}^{|\mathcal{X}|} \left[\sum_{x \in \mathcal{X}} f_j(x)^2 \pi(x) \right] \lambda_j^{2t},$$

che per quanto detto si semplifica in

$$(3.3.20) \quad \left\| \frac{P^t(x_0, \cdot)}{\pi(\cdot)} - 1 \right\|_2^2 = \sum_{j=2}^{|\mathcal{X}|} \lambda_j^{2t}.$$

Per quanto dimostrato precedentemente, questo conclude la dimostrazione dell'Equazione (3.3.13). $\square$

Torniamo agli esempi trattati nella sezione precedente e vediamo quale stima dall'alto è possibile ottenere.

Esempio 3.3.13. Consideriamo la versione lazy della passeggiata aleatoria simmetrica su $\mathbb{Z}_n$, con matrice di transizione $Q = \frac{P+I}{2}$. La catena è transitiva, quindi la distribuzione stazionaria è la distribuzione uniforme U , e possiamo applicare la Proposizione 3.3.12. Gli autovalori sono forniti dall'Equazione (3.3.9), e usando l'identità $\frac{1+\cos(2x)}{2} = \cos^2(x)$, otteniamo

$$\lambda_j(Q) = \cos^2\left(\frac{\pi j}{n}\right), \quad j = 0, 1, \dots, n-1.$$

Notiamo che $\lambda_j(Q) = \lambda_{n-j}(Q)$, quindi per ogni stato iniziale x vale

$$4\|Q^t(x, \cdot) - U\|_{\text{TV}}^2 \leq \sum_{j=1}^{n-1} \cos^{4t}\left(\frac{\pi j}{n}\right) \leq 2 \sum_{j=1}^{\lfloor n/2 \rfloor} \cos^{4t}\left(\frac{\pi j}{n}\right).$$

Per stimare questa somma, usiamo la disuguaglianza

$$\cos u \leq e^{-u^2/2} \quad \text{per ogni } u \in [0, \pi/2].$$

Questa segue considerando la funzione $h(u) = \log(e^{u^2/2} \cos u)$: abbiamo $h'(u) = u - \tan u \leq 0$, quindi $h(u) \leq h(0) = 0$, per $u \in [0, \pi/2]$.

Quindi otteniamo

$$\begin{aligned} 4\|Q^t(x, \cdot) - U\|_{\text{TV}}^2 &\leq 2 \sum_{j=1}^{\lfloor n/2 \rfloor} \exp\left(-\frac{2\pi^2 t j^2}{n^2}\right) \\ &= 2e^{-2\pi^2 t/n^2} \sum_{j=1}^{\lfloor n/2 \rfloor} \exp\left(-\frac{2\pi^2 t(j^2 - 1)}{n^2}\right). \end{aligned}$$

Usiamo la disuguaglianza $j^2 - 1 \geq 3(j-1)$, valida per ogni $j \geq 1$, per ricondurci a una serie geometrica:

$$\begin{aligned} 2e^{-2\pi^2 t/n^2} \sum_{j=1}^{\lfloor n/2 \rfloor} \exp\left(-\frac{2\pi^2 t(j^2 - 1)}{n^2}\right) &\leq 2e^{-2\pi^2 t/n^2} \sum_{j=1}^{\infty} \exp\left(-\frac{6\pi^2 t(j-1)}{n^2}\right) \\ &= \frac{2e^{-2\pi^2 t/n^2}}{1 - e^{-6\pi^2 t/n^2}}. \end{aligned}$$

In particolare, se $t = cn^2$ con $c \geq 1$, allora

$$d(t) \leq \frac{e^{-\pi^2 c}}{\sqrt{2(1 - e^{-6\pi^2 c})}} \leq e^{-\pi^2 c}.$$

Da questa disuguaglianza segue immediatamente che, per ogni $\varepsilon \in (0, 1/2)$ fissato, si ha

$$t_{\text{mix}}(\varepsilon) = \mathcal{O}(n^2).$$

Combinando questa stima con la stima dal basso fornita dall'Equazione (3.3.10) si ottiene

$$t_{\text{mix}}(\varepsilon) = \Theta(n^2).$$

Esempio 3.3.14. Consideriamo la versione lazy della passeggiata aleatoria sull'ipercubo descritta nell'Esempio 3.2.11. Procediamo come nell'esempio precedente. Gli autovalori della catena sono dati dall'Equazione (3.3.11). Usando la disuguaglianza (3.3.13) otteniamo

$$4\|Q^t(x, \cdot) - \pi\|_{\text{TV}}^2 \leq \sum_{k=1}^n \left(1 - \frac{k}{n}\right)^{2t} \binom{n}{k} \leq \sum_{k=1}^n e^{-2tk/n} \binom{n}{k} = \left(1 + e^{-2t/n}\right)^n - 1.$$

Per $t = \frac{1}{2}n \log n + cn$ la disuguaglianza diventa

$$(3.3.21) \quad 4\|Q^t(x, \cdot) - \pi\|_{\text{TV}}^2 \leq \left(1 + \frac{1}{n}e^{-2c}\right)^n - 1 \leq e^{e^{-2c}} - 1.$$

In altre parole, dopo il tempo $\frac{1}{2}n \log n$ la distanza dalla stazionarietà tende a 0 in una finestra temporale di ordine n .

3.3.4 Il metodo di Wilson per le stime dal basso

Abbiamo visto che conoscere gli autovalori della matrice di transizione permette di stimare dal basso il mixing time, ma che questo spesso non basta per ottenere la scala temporale corretta. Introduciamo un'importante tecnica che, tenendo conto anche delle autofunzioni, permette in molti casi di ottenere stime dal basso ottimali. È stata sviluppata da Wilson in [Wil04, Lemma 5, Sezione 3.3]. La useremo nel Capitolo 6 per ottenere una stima dal basso per il mixing time delle trasposizioni adiacenti.

L'idea è la seguente. Si sceglie una funzione Φ che sia autofunzione della matrice di transizione P , con autovalore reale λ vicino a 1. Notiamo che per ogni tempo $t \geq 0$ e per ogni stato $x \in \mathcal{X}$ vale

$$\mathbf{E}[\Phi(X_{t+1}) \mid X_t = x] = \sum_{y \in \mathcal{X}} P(x, y) \Phi(y) = (P\Phi)(x) = \lambda \Phi(x),$$

e quindi per induzione

$$\mathbf{E}_x[\Phi(X_t)] = \lambda^t \Phi(x).$$

Se la catena parte da uno stato x in cui $|\Phi(x)|$ è grande, il valore atteso di $\Phi(X_t)$ rimane distante da 0 finché la quantità $\lambda^t |\Phi(x)|$ è sufficientemente grande; invece dal Lemma 3.3.7 sappiamo che sotto la distribuzione stazionaria un'autofunzione non costante ha valore atteso nullo. Se sappiamo controllare quanto cambia in media la funzione Φ in

un passo della catena, possiamo stimare la varianza della variabile aleatoria $\Phi(X_t)$ e dimostrare che per tempi piccoli rispetto alla scala corretta il valore di $\Phi(X_t)$ resta concentrato attorno a un valore distante da 0. Questo ci permette di distinguere la distribuzione della catena dalla distribuzione stazionaria, e quindi ci permette di trovare una stima dal basso per il mixing time.

Teorema 3.3.15 (Metodo di Wilson). Sia (X_t) una catena di Markov irriducibile e aperiodica con spazio degli stati $\mathcal{X}$ e matrice di transizione P . Sia Φ un'autofunzione di P con autovalore reale λ tale che $\frac{1}{2} < \lambda < 1$. Fissato $\varepsilon \in (0, 1)$, sia $R > 0$ tale che valga

$$\mathbf{E}_x \left[|\Phi(X_1) - \Phi(x)|^2 \right] \leq R \quad \text{per ogni } x \in \mathcal{X}.$$

Allora, per ogni $x \in \mathcal{X}$,

$$(3.3.22) \quad t_{\text{mix}}(\varepsilon) \geq \frac{1}{2 \log(1/\lambda)} \left[\log \left(\frac{(1-\lambda)\Phi(x)^2}{2R} \right) + \log \left(\frac{1-\varepsilon}{\varepsilon} \right) \right].$$

Questo risultato è dimostrato in [LP17, Teorema 13.28].

Osservazione 3.3.16. Consideriamo i casi in cui λ è il secondo autovalore più grande e $\gamma_\star = \gamma = 1 - \lambda$ è piccolo. Usando l'espansione di Taylor al primo ordine, otteniamo

$$\frac{1}{\log(1/\lambda)} = \frac{1}{\gamma_\star + \mathcal{O}(\gamma_\star^2)} = t_{\text{rel}} (1 + \mathcal{O}(\gamma_\star)).$$

Il Teorema 3.3.8 afferma che

$$t_{\text{mix}}(\varepsilon) \geq \log \left(\frac{1}{2\varepsilon} \right) (t_{\text{rel}} - 1).$$

Quindi il termine $1/\log(1/\lambda)$ nell'Equazione (3.3.22) può essere interpretato come il relaxation time e il fattore restante, che dipende da Φ , determina quanto può essere migliorata la stima dal basso.

Capitolo 4

Fenomeno del cutoff

4.1 Definizione del cutoff

Per la distanza dalla stazionarietà del top-to-random shuffle su un mazzo di n carte, nel Capitolo 3 abbiamo ottenuto la stima dall'alto

$$d_n(\lceil n \log n + \alpha n \rceil) \leq e^{-\alpha}.$$

Come stima dal basso abbiamo ottenuto il fatto che, per ogni $\delta > 0$, esiste $\alpha(\delta) > 0$ tale che, per ogni $\alpha > \alpha(\delta)$,

$$\liminf_{n \rightarrow \infty} d_n(\lfloor n \log n - \alpha n \rfloor) \geq 1 - \delta.$$

Equivalentemente,

$$\lim_{\alpha \rightarrow \infty} \liminf_{n \rightarrow \infty} d_n(\lfloor n \log n - \alpha n \rfloor) = 1.$$

Queste due stime dicono che, attorno al tempo $n \log n$, la distanza dalla stazionarietà passa da valori vicini a 1 a valori vicini a 0 in una finestra temporale di ordine n , quindi trascurabile rispetto al tempo $n \log n$. Questo è un risultato più preciso rispetto al fatto che il mixing time è dell'ordine di $n \log n$.

Questo fenomeno si presenta in molti dei problemi di mixing che si affrontano, ed è detto **fenomeno del cutoff**. Per la definizione e i criteri generali, seguiremo [LP17, Capitolo 18].

Informalmente, data una successione di catene di Markov $(C_n)_{n \in \mathbb{N}}$, diciamo che c'è cutoff al tempo t_n se asintoticamente la transizione dalla totale assenza di mescolamento all'equilibrio avviene in una finestra temporale di ampiezza trascurabile rispetto a t_n . La definizione formale è la seguente.

Sia $(C_n)_{n \in \mathbb{N}}$ una successione di catene di Markov irriducibili e aperiodiche. Per ogni n , indichiamo con $\mathcal{X}_n$ lo spazio degli stati, con P_n la matrice di transizione, con π_n la distribuzione stazionaria e con $d_n(t) = \max_{x \in \mathcal{X}_n} \|P_n^t(x, \cdot) - \pi_n\|_{\text{TV}}$ la distanza dalla stazionarietà dell' n -esima catena.

Definizione 4.1.1. Diciamo che si verifica il *fenomeno del cutoff* per la successione (C_n) se esiste una successione (t_n) di reali positivi tali che

- $\lim_{n \rightarrow \infty} t_n = \infty$;
- per ogni $\varepsilon \in (0, 1)$, $\lim_{n \rightarrow \infty} d_n(\lfloor (1 + \varepsilon)t_n \rfloor) = 0$;
- per ogni $\varepsilon \in (0, 1)$, $\lim_{n \rightarrow \infty} d_n(\lfloor (1 - \varepsilon)t_n \rfloor) = 1$.

In questo caso diremo che la successione (C_n) ha cutoff al tempo t_n .




Figura 4.1.1: $d_n(t)$ tende ad essere una funzione a scalino per $n \rightarrow \infty$.

4.2 Esempi

Mostriamo che la catena del top to random shuffle soddisfa effettivamente la proprietà data dalla definizione di cutoff. Fissiamo $\varepsilon > 0$. Per la stima dall'alto, otteniamo direttamente

$$d_n(\lfloor (1 + \varepsilon)n \log n \rfloor) \leq e^{-\varepsilon \log n} = n^{-\varepsilon} \xrightarrow{n \rightarrow \infty} 0.$$

Per la stima dal basso, sappiamo che per ogni $\delta > 0$ esiste $\alpha(\delta) > 0$ tale che, per ogni $\alpha > \alpha(\delta)$,

$$\liminf_{n \rightarrow \infty} d_n(\lfloor n \log n - \alpha n \rfloor) \geq 1 - \delta.$$

Per n sufficientemente grande si ha $\varepsilon n \log n \geq \alpha n$. Quindi, usando il fatto che $d_n(t)$ è decrescente in t , otteniamo

$$d_n(\lfloor (1 - \varepsilon)n \log n \rfloor) \geq d_n(\lfloor n \log n - \alpha n \rfloor).$$

Passando al limite inferiore,

$$\liminf_{n \rightarrow \infty} d_n(\lfloor (1 - \varepsilon)n \log n \rfloor) \geq 1 - \delta.$$

Poiché $\delta > 0$ è arbitrario e, per definizione, $d_n(t) \leq 1$, segue che

$$\lim_{n \rightarrow \infty} d_n(\lfloor (1 - \varepsilon)n \log n \rfloor) = 1,$$

che è la stima dal basso richiesta nella definizione di cutoff al tempo $t_n = n \log n$.

Esempio 4.2.1 (Cutoff sull'ipercubo). Consideriamo la passeggiata aleatoria lazy sull'ipercubo $\mathbb{Z}_2^n$ descritta nell'Esempio 3.2.11. Si può dimostrare che questa successione di catene presenta cutoff al tempo $t_n = \frac{1}{2}n \log n$.

Per la stima dall'alto, l'Equazione (3.3.21) mostra che la distanza dalla stazionarietà tende a 0 in una finestra temporale di ordine n .

L'idea per la stima dal basso è invece la seguente. Supponiamo che la catena parta dall'identità del gruppo. Al tempo $t = (1 - \varepsilon)t_n$ molte delle coordinate non sono ancora state selezionate, e quindi sono rimaste uguali a 0, mentre all'equilibrio il numero di coordinate uguali a 0 è concentrato attorno a $n/2$. Questa differenza permette di mostrare che $d_n(\lfloor (1 - \varepsilon)t_n \rfloor) \rightarrow 1$.

Una dimostrazione completa del cutoff per l'ipercubo si può trovare in [LP17, Teorema 18.3].

Vediamo adesso una famiglia di passeggiate aleatorie per cui non si verifica il fenomeno del cutoff.

Esempio 4.2.2 (Assenza di cutoff su $\mathbb{Z}_n$). Usiamo il seguente fatto: per una successione di catene irriducibili, aperiodiche e reversibili, una condizione necessaria per il cutoff è che

$$\frac{t_{\text{mix}}^{(n)}}{t_{\text{rel}}^{(n)} - 1} \xrightarrow{n \rightarrow \infty} \infty,$$

come mostrato in [LP17, Proposizione 18.4]. Intuitivamente, il relaxation time misura la scala temporale su cui decade il modo più lento della catena. Se questa ha lo stesso ordine del mixing time, la distanza dalla stazionarietà non può passare bruscamente da valori vicini a 1 a valori vicini a 0, e quindi non ci può essere cutoff.

Dato che $t_{\text{mix}}^{(n)} = \Theta(n^2)$ e $t_{\text{rel}}^{(n)} = \Theta(n^2)$, non ci può essere cutoff.

Capitolo 5

Trasposizioni aleatorie

In questo e nel prossimo capitolo esaminiamo in dettaglio due problemi centrali nella teoria moderna delle catene di Markov e del mixing. Per farlo, useremo le tecniche sviluppate nel Capitolo 3: in questo capitolo faremo uso degli strong stationary times, mentre nel Capitolo 6 faremo uso del coupling e dei metodi spettrali.

5.1 Introduzione al problema

Ricordiamo il problema delle trasposizioni aleatorie presentato nell'Esempio 1.2.2: abbiamo un mazzo di n carte numerate da 1 a n . Al tempo t , scegliamo in maniera uniforme e indipendente due carte L_t e R_t . Se sono diverse, le scambiamo, altrimenti non facciamo nulla. Questo corrisponde alla passeggiata aleatoria sul gruppo simmetrico S_n con transizioni date da

$$\mu(\sigma) = \begin{cases} \frac{1}{n}, & \text{se } \sigma = \text{id}, \\ \frac{2}{n^2}, & \text{se } \sigma = (ij), \\ 0, & \text{altrimenti.} \end{cases}$$

Osserviamo preliminarmente che le trasposizioni formano un sistema di generatori per S_n , il che garantisce l'irriducibilità della catena. Dato che $\mu(\text{id}) > 0$, la catena è anche aperiodica. Inoltre, essendo la passeggiata aleatoria transitiva, possiamo limitarci senza perdita di generalità a considerare l'evoluzione della catena partendo dall'identità.

Il problema della stima del mixing time per le trasposizioni aleatorie è stato molto studiato ed è stato risolto per la prima volta nel 1981 da Persi Diaconis e Mehrdad Shahshahani nell'articolo [DS81], in cui hanno dimostrato che c'è cutoff al tempo

$$t_n = \frac{1}{2}n \log n.$$

Questo risultato è stato ottenuto usando tecniche derivanti dalla teoria delle rappresentazioni.

Il problema è stato affrontato anche con la tecnica degli strong stationary times, a partire da Broder che nel 1985 ha ottenuto una stima dall'alto di $2n \log n$ per il mixing time. Successivamente Matthews [Mat88] ha modificato questa costruzione con l'obiettivo di ottenere la stima ottimale di $\frac{1}{2}n \log n$. Come osservato da White nella sua tesi di dottorato [Whi17], questa modifica presenta un errore sottile. In questo capitolo analizzeremo la costruzione originale di Broder e il tentativo di Matthews di ottenere la stima di $\frac{1}{2}n \log n$, spiegando perché non funziona. In seguito vedremo cosa si può conservare dell'idea di Matthews, ottenendo una stima dall'alto per il mixing time di $\frac{5}{4}n \log n$. Infine mostreremo come ottenere una stima dal basso per la scala temporale corretta di $\frac{1}{2}n \log n$.

5.2 Costruzione di Broder

Analizziamo la costruzione di uno strong stationary time proposta da Broder [Bro85] seguendo la presentazione di [LP17, Proposizione 8.6], adattata alla nozione di carte fortemente mescolate introdotta sotto. Il lavoro originale di Broder non è mai stato pubblicato; la sua costruzione è discussa anche in [Dia88]. L'idea è quella di colorare le carte man mano che la catena procede, in modo che l'ordine relativo delle carte colorate sia uniforme. Lo strong stationary time τ_n è il primo istante in cui tutte le carte sono colorate.

In realtà, avremo bisogno di una nozione più forte rispetto all'uniformità dell'ordine relativo: introduciamo quindi la seguente definizione, adattata da [Whi17, Definizione 5.1].

Definizione 5.2.1. Data una distribuzione di probabilità ν definita su S_n , diciamo che le carte nell'insieme $C \subseteq [n]$ sono *fortemente mescolate tra loro* se ν è invariante per permutazione delle carte in C . Equivalentemente, per ogni $\pi \in S_n$ e per ogni permutazione $\rho \in S_n$ tale che $\rho(c) = c$ per ogni $c \notin C$, vale $\nu(\rho \circ \pi) = \nu(\pi)$.

Notiamo che questa definizione non richiede solamente che le carte dell'insieme C abbiano la stessa probabilità di trovarsi in ciascun possibile ordine relativo, ma anche che ciò sia indipendente dalle posizioni delle altre carte. Ad esempio, se consideriamo la distribuzione su S_4 che associa probabilità $\frac{1}{2}$ alle permutazioni 2143 e 3412, le carte 1 e 4 non sono fortemente mescolate tra loro.

Prima di dimostrare che la costruzione di Broder fornisce uno strong stationary time, introduciamo un lemma adattato da [Whi17, Lemma 5.2].

Lemma 5.2.2. Sia (π_t) una passeggiata aleatoria su S_n con transizioni date da μ e sia ν_t la distribuzione della catena al tempo t . Sia $C \subseteq [n]$ un insieme di carte e sia $G_C = \{\rho \in S_n : \rho(c) = c \text{ per ogni } c \notin C\}$. Supponiamo che la distribuzione μ sia invariante per coniugio degli elementi di G_C , ovvero che $\mu(g) = \mu(\rho g \rho^{-1})$ per ogni $g \in S_n$, $\rho \in G_C$.

Se le carte in C sono fortemente mescolate tra loro rispetto alla distribuzione ν_t , allora lo sono anche rispetto alla distribuzione ν_{t+1} .

Dimostrazione. La distribuzione al tempo $t+1$ è $\nu_{t+1} = \mu * \nu_t$. Data $\rho \in G_C$ e $g \in S_n$, tramite la sostituzione $h = \rho k$ otteniamo

$$\begin{aligned}\nu_{t+1}(\rho g) &= \sum_{h \in S_n} \mu(\rho g h^{-1}) \nu_t(h) \\ &= \sum_{k \in S_n} \mu(\rho g k^{-1} \rho^{-1}) \nu_t(\rho k) \\ &= \sum_{k \in S_n} \mu(\rho g k^{-1} \rho^{-1}) \nu_t(k) \\ &= \sum_{k \in S_n} \mu(g k^{-1}) \nu_t(k) \\ &= \nu_{t+1}(g).\end{aligned}$$

Nella terza uguaglianza usiamo che le carte in C sono fortemente mescolate tra loro rispetto a ν_t , mentre nella quarta usiamo l'invarianza per coniugio della distribuzione μ . $\square$

Quando l'insieme C è aleatorio, diremo che le carte in C sono fortemente mescolate tra loro se, condizionatamente al valore di C , la distribuzione è invariante per permutazioni delle carte in C .

Proposizione 5.2.3. Nel problema delle trasposizioni aleatorie, siano L_t e R_t le carte scelte dalla mano sinistra e dalla mano destra al tempo t rispettivamente. Quando $t = 0$, nessuna carta è colorata. Al tempo t , coloriamo la carta R_t se le seguenti due condizioni sono rispettate:

- R_t non è colorata;
- L_t è colorata o $L_t = R_t$.

Sia τ_n il primo istante in cui ogni carta risulta colorata. Allora τ_n è uno strong stationary time per la catena.

L'idea che sta dietro a questo modo di colorare le carte è la seguente. Un modo di generare una permutazione casuale uniforme consiste nel costruire un mazzo di carte inserendo una carta alla volta, mettendo ciascuna carta in una posizione scelta uniformemente rispetto a quelle già presenti nel mazzo. Nel caso dello strong stationary time appena descritto, le carte colorate eseguono esattamente questo processo.

Dimostrazione della Proposizione 5.2.3. Sia C_t l'insieme delle carte colorate al tempo t . Per dimostrare che τ_n è uno strong stationary time, dimostriamo per induzione su t che, condizionando sul valore di C_t , le carte in C_t sono fortemente mescolate tra loro.

Il claim è banalmente vero per $t = 0$.

Assumiamo che sia vero al tempo t . Se non viene colorata nessuna nuova carta, ovvero $C_{t+1} = C_t$, allora il claim segue dal Lemma 5.2.2. Più precisamente, fissato

$C_t = C$, condizionare al fatto che nessuna nuova carta venga colorata modifica la probabilità delle transizioni μ , ma questa rimane comunque invariante per coniugio rispetto alle permutazioni delle carte in C .

Rimane da controllare che le carte colorate siano fortemente mescolate tra loro al tempo $t + 1$ quando viene colorata una nuova carta, che sarà necessariamente R_{t+1} .




Figura 5.2.1: Esempio di cosa succede quando viene colorata una nuova carta, che assumiamo essere il 4. Le carte 2 e 5 sono già colorate. Le posizioni delle carte colorate diventano $\{1, 3, 5\}$, e L_{t+1} è uniformemente distribuita in $\{2, 4, 5\}$.

Condizioniamo quindi sul valore dell'insieme C_t e sul valore della nuova carta colorata: siano $C_t = C$ e $R_{t+1} = w \notin C$. Per dimostrare che le carte in $C_{t+1} = C \cup \{w\}$ sono fortemente mescolate tra loro, dobbiamo dimostrare che il loro ordine relativo è uniforme anche condizionando sulla disposizione delle carte non appartenenti a C_{t+1} . Sotto queste ipotesi, L_{t+1} è uniformemente distribuita in C_{t+1} e, per ipotesi induttiva, l'ordine relativo delle carte in C_t è uniforme. Queste due informazioni determinano in modo univoco l'ordine relativo delle carte in C_{t+1} . Dato che le scelte sono uniformi e indipendenti, tutte le permutazioni risultanti sono equiprobabili.

Per concludere, usiamo il Lemma 3.2.7: invece di verificare l'uniformità condizionata all'evento $\tau_n = t$, possiamo condizionare sull'evento $\tau_n \leq t$, che corrisponde all'evento $C_t = [n]$. Per quanto dimostrato, condizionatamente a tale evento le carte sono fortemente mescolate tra loro, ovvero per ogni $\sigma \in S_n$ vale $\mathbf{P}(\pi_t = \sigma \mid \tau_n \leq t) = \frac{1}{n!}$, e quindi τ_n è uno strong stationary time. □

Osservazione 5.2.4. La dimostrazione del fatto che il tempo costruito nel Capitolo 3 è uno strong stationary time per il top to random shuffle può essere riscritta in modo simile a quella appena vista, evitando di condizionare esplicitamente sui tempi T_i e dimostrando invece che, condizionatamente al valore dell'insieme C_t , l'ordine relativo delle carte in C_t è uniforme. Quando C_t contiene tutte le carte, il Lemma 3.2.7 permette di concludere che il tempo costruito è uno strong stationary time.

Osservazione 5.2.5. La dimostrazione della Proposizione 5.2.3 presenta una sottigliezza. Seguendo [Whi17, Osservazione 5.5], osserviamo che la Definizione 5.2.1 non richiede solamente che l'ordine relativo delle carte colorate sia uniforme, ma anche che ciò sia indipendente dalle posizioni delle altre carte. Questa ipotesi aggiuntiva viene usata in quella dimostrazione quando viene colorata una nuova carta: se la posizione di

questa carta può dipendere dall'ordine relativo delle carte già colorate, il nuovo insieme di carte colorate non ha necessariamente ordine relativo uniforme.

Vediamo un esempio concreto: consideriamo la distribuzione di probabilità su S_4 che associa probabilità $\frac{1}{2}$ alle permutazioni 2143 e 3412. Rispetto a questa distribuzione, le carte nell'insieme $\{1, 4\}$ hanno ordine relativo uniforme, ma ciò non è indipendente dalle posizioni delle altre carte. Se partiamo da questa distribuzione e trasponiamo la carta 2 con una carta scelta uniformemente dall'insieme $\{1, 2, 4\}$, l'ordine relativo delle carte 1, 2, 4 non è uniforme; in particolare non è possibile ottenere l'ordine relativo 142.

Vediamo adesso che tipo di risultato si può ottenere con questo strong stationary time. Per controllare la coda di τ_n , stimiamo prima valore atteso e varianza, come in [LP17, Lemma 8.9].

Lemma 5.2.6. Lo strong stationary time definito nella Proposizione 5.2.3 soddisfa

$$\mathbf{E}(\tau_n) = 2n \log n + \mathcal{O}(n)$$

e

$$\text{Var}(\tau_n) = \mathcal{O}(n^2).$$

Dimostrazione. Sia $\tau_n^{(k)}$ il minimo numero di passi affinché k carte siano colorate e poniamo $\tau_n^{(0)} = 0$. Allora $\tau_n^{(k)} - \tau_n^{(k-1)}$ è il numero di passi per passare da $k-1$ carte colorate a k carte colorate e possiamo scrivere τ_n come

$$\tau_n = \sum_{k=1}^n \left(\tau_n^{(k)} - \tau_n^{(k-1)} \right).$$

Le variabili aleatorie $\tau_n^{(k)} - \tau_n^{(k-1)}$ hanno distribuzione geometrica con probabilità di successo $\frac{k(n-k+1)}{n^2}$ e sono indipendenti. Otteniamo quindi

$$\mathbf{E}(\tau_n) = \sum_{k=1}^n \frac{n^2}{k(n-k+1)}$$

Sostituendo la decomposizione

$$\frac{1}{k(n-k+1)} = \frac{1}{n+1} \left(\frac{1}{k} + \frac{1}{n-k+1} \right)$$

e ricordando che

$$\sum_{j=1}^n \frac{1}{j} = \log n + \mathcal{O}(1)$$

si ottiene la stima desiderata.

Per la varianza, scriviamo

$$\text{Var}(\tau_n) = \sum_{k=1}^n \frac{1 - \frac{k(n-k+1)}{n^2}}{\left(\frac{k(n-k+1)}{n^2}\right)^2} < \sum_{k=1}^n \frac{n^4}{k^2(n-k+1)^2}.$$

Dividiamo la somma in due parti:

$$\begin{aligned} \text{Var}(\tau_n) &< \sum_{1 \leq k \leq n/2} \frac{n^4}{k^2(n-k+1)^2} + \sum_{n/2 < k \leq n} \frac{n^4}{k^2(n-k+1)^2} \\ &< \frac{2n^4}{(n/2)^2} \sum_{1 \leq k \leq (n+1)/2} \frac{1}{k^2} = \mathcal{O}(n^2). \end{aligned}$$

□

Corollario 5.2.7. Sia C_n la catena delle trasposizioni aleatorie per il mazzo da n carte e $d_n(t)$ la distanza dell' n -esima catena dalla stazionarietà al tempo t . Allora per ogni $\varepsilon \in (0, 1)$ e per $t_n = 2n \log n$ si ha

$$\lim_{n \rightarrow \infty} d_n(\lfloor (1 + \varepsilon)t_n \rfloor) = 0.$$

Dimostrazione. Per la Proposizione 3.2.6 e il Lemma 5.2.6

$$\begin{aligned} d_n((1 + \varepsilon)t_n) &\leq \mathbf{P}(\tau_n > (1 + \varepsilon)t_n) \\ &= \mathbf{P}(\tau_n > 2n \log n + 2\varepsilon n \log n) \\ &= \mathbf{P}(\tau_n - \mathbf{E}[\tau_n] > 2\varepsilon n \log n - \mathcal{O}(n)) \\ &\leq \mathbf{P}(\tau_n - \mathbf{E}[\tau_n] > \varepsilon n \log n) \\ &\leq \mathbf{P}(|\tau_n - \mathbf{E}[\tau_n]| > \varepsilon n \log n) \end{aligned}$$

Applicando la disuguaglianza di Chebyshev, otteniamo:

$$\begin{aligned} &\leq \frac{\text{Var}(\tau_n)}{(\varepsilon n \log n)^2} \\ &= \frac{\mathcal{O}(n^2)}{\varepsilon^2 n^2 \log^2 n} \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

□

5.3 Costruzione di Matthews

Il Corollario 5.2.7 dimostra la prima delle due disuguaglianze nella Definizione 4.1.1 che bisognerebbe avere affinché ci fosse cutoff al tempo $2n \log n$.

Il tentativo di Matthews di ottenere cutoff al tempo $\frac{1}{2}n \log n$, presentato nell'articolo [Mat88], si basa sulle seguenti due osservazioni:

- Notiamo che l'algoritmo di Broder è molto lento all'inizio, quando poche carte sono colorate; in particolare bisogna fare in media n passi per colorare la prima carta. Cerchiamo quindi un modo diverso per colorare le carte quando ce ne sono ancora poche colorate.
- Quando ci sono tante carte colorate, l'algoritmo di Broder è veloce. Vedremo che, con una piccola modifica, può essere reso due volte più veloce.

5.3.1 Prima parte dell'algoritmo

Matthews ha quindi proposto un nuovo modo di colorare le carte diviso in due parti, a seconda che siano state colorate più o meno di $\lceil \frac{n}{3} \rceil$ carte. Nella prima parte dell'algoritmo coloriamo le carte secondo la seguente regola:

- Se L_t e R_t sono entrambe non colorate, coloriamo R_t .

Vediamo l'idea che sta dietro a questo modo di colorare le carte. Un modo di costruire una permutazione casuale uniforme è il seguente: a ogni passo selezioniamo in maniera uniforme e indipendente una carta C e una posizione p . Se nessuna delle due era stata scelta in precedenza, si accetta la coppia (p, C) e si mette la carta C nella posizione p , altrimenti la coppia viene scartata. Il processo di mescolamento simula questa dinamica: la mano destra sceglie la carta R_t , la mano sinistra sceglie la posizione $\pi_t^{-1}(L_t)$. Quando si effettua la trasposizione (L_t, R_t) la carta scelta dalla mano destra viene inserita nella posizione scelta dalla mano sinistra. Se entrambe le carte sono non colorate, la coppia viene accettata colorando la carta R_t .




Figura 5.3.1: Idea del perché il modo di colorare le carte funziona.

Dimostriamo che l'ordine relativo delle carte colorate è uniforme. L'idea della dimostrazione è la seguente: per costruire la permutazione π_t introduciamo l'insieme $E = [n]$ delle etichette. Definiamo due variabili aleatorie a valori in S_n :

- φ_t associa le etichette alle carte;

- ψ_t associa le etichette alle posizioni.

Dunque la permutazione π_t si scrive come $\pi_t = \varphi_t \circ \psi_t^{-1}$. Quando k carte sono colorate, assegniamo loro le etichette $[k]$. Dimostreremo che $(\varphi_t(1), \dots, \varphi_t(k))$ e $(\psi_t(1), \dots, \psi_t(k))$ sono indipendenti e uniformemente distribuite tra le k -uple ordinate di elementi distinti di $[n]$.

Passiamo adesso alla dimostrazione formale. Per $k \leq \lceil \frac{n}{3} \rceil$, diciamo che una variabile aleatoria X a valori in S_n soddisfa la proprietà P_k se può essere scritta come la composizione $\varphi \circ \psi^{-1}$, dove φ e ψ sono variabili aleatorie a valori in S_n e $(\varphi(1), \dots, \varphi(k))$ e $(\psi(1), \dots, \psi(k))$ sono indipendenti e uniformemente distribuite tra le k -uple ordinate di elementi distinti di $[n]$. Notiamo che questa proprietà implica che l'ordine relativo delle carte colorate sia uniforme ma non che ciò sia indipendente dalla disposizione delle carte non colorate, e quindi non implica che le carte colorate siano fortemente mescolate tra loro nel senso della Definizione 5.2.1.

Proposizione 5.3.1. Per ogni tempo t e per ogni $k \leq \lceil \frac{n}{3} \rceil$, condizionatamente al fatto che esattamente k carte siano colorate, la variabile aleatoria π_t soddisfa la proprietà P_k .

Dimostrazione. Costruiamo φ_t e ψ_t induttivamente. Per il passo base, abbiamo $t = 1$ e $\pi_1 = (L_1, R_1)$. Vogliamo assegnare l'etichetta 1 a L_1 tramite ψ_1 e a R_1 tramite φ_1 , facendo in modo che $\varphi_1 \circ \psi_1^{-1} = (L_1, R_1)$. Poniamo allora

$$\psi_1 = (1, L_1)$$

e

$$\varphi_1 = \begin{cases} (1, R_1) \circ (L_1, R_1) & \text{se } L_1 \neq 1 \text{ e } R_1 \neq 1; \\ (1, R_1) & \text{altrimenti.} \end{cases}$$

Allora $\varphi_1 \circ \psi_1^{-1} = (L_1, R_1)$. Dobbiamo verificare solo la proprietà P_1 , dato che al tempo 1 è colorata al più una carta. P_1 è verificata perché $\psi_1(1) = L_1$ e $\varphi_1(1) = R_1$ sono indipendenti e uniformemente distribuiti per ipotesi.




Figura 5.3.2: Schema della costruzione di φ_1 e ψ_1 .

Per il passo induttivo, supponiamo che la Proposizione 5.3.1 sia vera al tempo t , quindi che $\pi_t = \varphi_t \circ \psi_t^{-1}$, e che esattamente k carte siano colorate al tempo t per qualche $1 \leq k \leq \lceil \frac{n}{3} \rceil$. Bisogna considerare due casi:

- Se viene colorata una nuova carta al tempo $t + 1$, allora π_{t+1} soddisfa P_{k+1} .
- Se non viene colorata nessuna nuova carta, P_k è ancora soddisfatta.

Consideriamo il primo caso. Siano $l = \varphi_t^{-1}(L_{t+1})$ e $r = \varphi_t^{-1}(R_{t+1})$ le etichette assegnate alle carte L_{t+1} e R_{t+1} al tempo t rispettivamente. Siano $p_L = \pi_t^{-1}(L_{t+1})$ e $p_R = \pi_t^{-1}(R_{t+1})$ le posizioni occupate dalle carte L_{t+1} e R_{t+1} al tempo t rispettivamente.




Figura 5.3.3: Situazione al tempo t .

Affinché la proprietà P_{k+1} sia soddisfatta, occorre che ψ_{t+1} mandi l'etichetta $k + 1$ nella posizione della nuova carta colorata e φ_{t+1} mandi l'etichetta $k + 1$ nella nuova carta colorata, ovvero $\psi_{t+1}(k + 1) = p_L$ e $\varphi_{t+1}(k + 1) = R_{t+1}$.

Dato che le carte L_{t+1} e R_{t+1} non erano colorate al tempo t , esse non appartengono all'insieme $\{\varphi_t(1), \dots, \varphi_t(k)\}$, ovvero $l, r \notin [k]$. Se troviamo il modo di rinominare le etichette da $k + 1$ a n in modo tale che l'etichetta $k + 1$ diventi l'etichetta l , allora componendo con ψ_t questa sarà mandata in p_L , come voluto. Analogamente, se troviamo il modo di rinominare le etichette da $k + 1$ a n in modo tale che l'etichetta $k + 1$ diventi l'etichetta r , allora componendo con φ_t questa sarà mandata in R_{t+1} . Poniamo quindi $\psi_{t+1} = \psi_t \circ f$ con $f \in S_n$, $f(k + 1) = l$, e $\varphi_{t+1} = \varphi_t \circ g$, con $g \in S_n$, $g(k + 1) = r$. È chiaro inoltre che moltiplicare a sinistra π_t per (L_{t+1}, R_{t+1}) corrisponde a scambiare le etichette l, r :

$$\pi_{t+1} = (L_{t+1}, R_{t+1}) \circ \varphi_t \circ \psi_t^{-1} = \varphi_t \circ (\varphi_t^{-1}(L_{t+1}), \varphi_t^{-1}(R_{t+1})) \circ \psi_t^{-1} = \varphi_t \circ (l, r) \circ \psi_t^{-1}.$$

Cerchiamo quindi due permutazioni $f, g \in S_n$ tali che

- $f|_{\{1, 2, \dots, k\}} = \text{id}_{\{1, 2, \dots, k\}}$;
- $g|_{\{1, 2, \dots, k\}} = \text{id}_{\{1, 2, \dots, k\}}$;
- $f(k + 1) = l$;
- $g(k + 1) = r$;

- $g \circ f^{-1} = (l, r)$.

Questo corrisponde a quanto fatto nel passo base con 1 al posto di $k + 1$, L_1 al posto di l e R_1 al posto di r . Poniamo quindi

$$\psi_{t+1} = \psi_t \circ (k + 1, l)$$

e

$$\varphi_{t+1} = \begin{cases} \varphi_t \circ (k + 1, r) \circ (l, r) & \text{se } l \neq k + 1 \text{ e } r \neq k + 1, \\ \varphi_t \circ (k + 1, r) & \text{altrimenti.} \end{cases}$$

Per verificare P_{k+1} , notiamo che

$$(\varphi_{t+1}(1), \dots, \varphi_{t+1}(k), \varphi_{t+1}(k + 1)) = (\varphi_t(1), \dots, \varphi_t(k), \textcolor{red}{R}_{t+1})$$

e

$$(\psi_{t+1}(1), \dots, \psi_{t+1}(k), \psi_{t+1}(k + 1)) = (\psi_t(1), \dots, \psi_t(k), \textcolor{red}{p}_L)$$

Condizionatamente all'essere nel caso in cui viene colorata una nuova carta, R_{t+1} è uniformemente distribuita in $[n] \setminus \{\varphi_t(1), \dots, \varphi_t(k)\}$ e p_L è uniformemente distribuita in $[n] \setminus \{\psi_t(1), \dots, \psi_t(k)\}$. Inoltre, dall'indipendenza di R_{t+1} , L_{t+1} e π_t segue l'indipendenza di R_{t+1} e $\pi_t^{-1}(L_{t+1}) = p_L$. La proprietà P_{k+1} segue quindi dall'ipotesi induttiva.

Passiamo adesso al secondo caso. Ci sono due sottocasi da considerare: possono venire scambiate due carte colorate oppure una carta colorata e una non colorata.

Se vengono scambiate due carte colorate, $l, r \in [k]$. In questo caso basta scambiare le etichette assegnate alle carte L_{t+1} e R_{t+1} . Poniamo quindi $\psi_{t+1} = \psi_t$ e $\varphi_{t+1} = \varphi_t \circ (l, r)$. Dato che l, r sono indipendenti da ψ_t , l'indipendenza delle k -uple è preservata. Dato che (l, r) è indipendente da φ_t , l'invarianza per composizione a destra per elementi del gruppo S_k garantisce che la distribuzione marginale uniforme sia preservata.

Se vengono scambiate una carta colorata e una non colorata, esattamente uno tra l e r è maggiore di k . Assumiamo senza perdita di generalità che $l \leq k$ e $r > k$. La carta colorata L_{t+1} viene messa nella posizione p_R . Bisogna quindi scambiare le etichette che vengono assegnate alle posizioni p_L, p_R . Poniamo $\varphi_{t+1} = \varphi_t$ e $\psi_{t+1} = \psi_t \circ (l, r)$. L'indipendenza delle k -uple è analoga al caso precedente. Per la distribuzione marginale di $(\psi_{t+1}(1), \dots, \psi_{t+1}(k))$ notiamo che la posizione p_L è stata sostituita da una posizione scelta uniformemente in $[n] \setminus \{\psi_t(1), \dots, \psi_t(k)\}$. Se un elemento scelto uniformemente da una k -upla di elementi di $[n]$ distribuita uniformemente viene sostituito da un elemento scelto uniformemente tra i rimanenti, la k -upla risultante è uniformemente distribuita. $\square$

La Proposizione 5.3.1 implica che, finché si usa la prima parte dell'algoritmo, l'ordine relativo delle carte colorate è uniforme.

La nuova posizione della carta
colorata diventa una delle rimanenti,
scelta uniformemente




Figura 5.3.4: Caso in cui vengono scambiate una carta colorata e una non colorata.

5.3.2 Seconda parte dell'algoritmo

Una volta che sono state colorate $\lceil \frac{n}{3} \rceil$ carte, cambiamo regola di colorazione e passiamo alla seconda parte dell'algoritmo di Matthews, in cui viene ripreso l'algoritmo di Broder e modificato per colorare le carte due volte più velocemente. Chiameremo questo nuovo algoritmo "Broder accelerato".

L'idea di partenza è quella di ripristinare la simmetria tra mano destra e mano sinistra: al tempo t , se esattamente una tra L_t e R_t è colorata, coloriamo la carta non colorata. Il problema è che condizionatamente all'essere colorata, la nuova carta colorata ha probabilità diverse di occupare le varie posizioni. È due volte più probabile che vada nella posizione di una specifica carta già colorata piuttosto che resti nella sua posizione. Per ripristinare l'uniformità, dobbiamo far sì che la probabilità che una nuova carta venga colorata e rimanga nella sua posizione passi da $\frac{1}{n^2}$ a $\frac{2}{n^2}$. L'idea è di sfruttare le mosse in cui vengono pescate due carte già colorate: se associamo a ciascuna carta non colorata una coppia distinta di carte già colorate, possiamo far corrispondere l'estrazione di una data coppia alla colorazione della carta corrispondente.

L'algoritmo "Broder accelerato" è quindi il seguente: siano $C_1 < C_2 < \dots < C_k$ le carte colorate e $D_1 < D_2 < \dots < D_{n-k}$ le carte non colorate.

Ordiniamo in modo lessicografico le k^2 coppie di carte colorate:

$$(5.3.1) \quad (C_1, C_1), (C_1, C_2), \dots, (C_k, C_k)$$

Al tempo t , coloriamo la carta D_i se si verifica uno di questi eventi:

- $(L_t, R_t) = (D_i, D_i)$
- Una mano sceglie D_i e l'altra sceglie una carta colorata qualsiasi.
- Viene estratta esattamente l' i -esima coppia dalla lista (5.3.1).

5.3.3 L'errore nella costruzione di Matthews

Mostriamo quindi perché l'algoritmo di Matthews non funziona, seguendo la descrizione in [Whi17, Sezione 5.3]. Il motivo è spiegato dall'Osservazione 5.2.5: per poter passare dall'algoritmo iniziale alla seconda parte, non basta che l'ordine relativo delle carte colorate sia uniforme: serve anche che questa uniformità sia indipendente dalle posizioni delle carte non colorate. La prima parte dell'algoritmo non garantisce questa condizione, necessaria per far partire Broder accelerato. Vediamolo con un esempio esplicito.

Consideriamo la catena delle trasposizioni aleatorie su S_4 . Condizioniamo sull'evento che nei primi tre passi vengano colorate rispettivamente le carte 1, 4, 2: le carte 1 e 4 vengono colorate usando la prima parte dell'algoritmo, mentre la carta 2 viene colorata usando Broder accelerato.

Al primo passo, affinché venga colorata la carta 1, la mano destra deve scegliere 1, mentre la mano sinistra può scegliere una qualunque delle quattro carte. Quindi, partendo dall'identità, dopo il primo passo si possono ottenere le permutazioni

$$1234, \quad 2134, \quad 3214, \quad 4231,$$

con la stessa probabilità condizionata. Al secondo passo viene colorata la carta 4. Dato che la carta 1 è già colorata, la mano destra deve scegliere 4 e la mano sinistra deve scegliere una delle carte non colorate 2, 3, 4. Dopo due passi si ottengono quindi le dodici permutazioni

$$\begin{array}{ll} 1432, 1243, 1234, & 4132, 2143, 2134, \\ 3412, 4213, 3214, & 2431, 3241, 4231. \end{array}$$

Queste dodici possibilità sono equiprobabili condizionatamente all'evento che le prime due carte colorate siano 1 e 4.

Passiamo ora al terzo passo. Le carte colorate sono 1 e 4, mentre le carte non colorate sono 2 e 3. Quindi, nella notazione dell'algoritmo, $D_1 = 2$ e la prima coppia colorata nella lista (5.3.1) è (1, 1). La carta 2 può essere colorata nei seguenti casi:

scelta al terzo passo	permutazione applicata	probabilità
$(L_3, R_3) = (2, 2)$	id	1/16
$(L_3, R_3) = (1, 1)$	id	1/16
$\{L_3, R_3\} = \{1, 2\}$	(1 2)	2/16
$\{L_3, R_3\} = \{2, 4\}$	(2 4)	2/16

Condizionatamente al fatto che al terzo passo venga colorata la carta 2, le tre mosse effettive

$$\text{id}, \quad (1\ 2), \quad (2\ 4)$$

hanno la stessa probabilità. Quindi le configurazioni possibili dopo tre passi sono le trentasei permutazioni ottenute dalle dodici precedenti applicando una tra queste tre mosse. Nella tabella seguente, adattata da [Whi17, Tabella 5.5], sono disposte le dodici

permutazioni ottenute dopo due passi in modo da mostrare dove nasce il problema. Ogni riga contiene, nella colonna di destra, le tre permutazioni che si possono ottenere al passo successivo applicando rispettivamente $(1\ 2)$, $(2\ 4)$ oppure l'identità.

dopo due passi	dopo tre passi
1432	2431, 1234, 1432
4132	4231, 2134, 4132
1243	2143, 1423, 1243
4213	4123, 2413, 4213
1234	2134, 1432, 1234
4231	4132, 2431, 4231
2134	1234, 4132, 2134
2431	1432, 4231, 2431
3214	3124, 3412, 3214
3241	3142, 3421, 3241
2143	1243, 4123, 2143
3412	3421, 3214, 3412

Le prime dieci righe si accoppiano in cinque coppie: in ciascuna coppia, i sei ordini relativi possibili delle carte 1, 2, 4 compaiono esattamente una volta. Le ultime due righe mostrano dove fallisce l'accoppiamento, e la loro presenza è il motivo per cui le carte 1 e 4 non sono fortemente mescolate tra loro dopo due passi. La riga corrispondente a 3412 sarebbe bilanciata dalla riga 3142, che però non compare tra le configurazioni ottenute dopo due passi. Al suo posto compare 2143, e applicando le tre mosse possibili a 2143 e 3412 non si ottengono i sei ordini relativi una volta ciascuno.

Se l'algoritmo di Matthews funzionasse, allora, condizionatamente a questo evento, i sei possibili ordini relativi delle carte 1, 2, 4 dovrebbero comparire con la stessa frequenza. Invece un conteggio diretto dà:

ordine relativo	124	142	214	241	412	421
frequenza	6	5	7	5	7	6

Quindi l'ordine relativo delle carte 1, 2, 4 non è uniforme. Questo mostra che la dimostrazione di Matthews non è corretta.

5.3.4 Risultati

Vediamo cosa si può conservare della costruzione di Matthews. Dalla trattazione nella sezione precedente è chiaro che la prima parte dell'algoritmo non basta per avviare né l'algoritmo di Broder classico né l'algoritmo di Broder accelerato. Inoltre, usare quella procedura per colorare tutte le carte dà soltanto una stima dall'alto per il mixing time dell'ordine di n^2 .

Per avviare Broder accelerato, abbiamo bisogno di un certo numero di carte già colorate; in particolare averne $\lceil \sqrt{n} \rceil$ è sufficiente per associare a ciascuna carta non

colorata una coppia di carte colorate. Per garantire la corretta ipotesi induttiva utilizziamo l'algoritmo classico di Broder fino ad aver colorato $\lceil \sqrt{n} \rceil$ carte, e poi passiamo a Broder accelerato.

Proposizione 5.3.2. Nel problema delle trasposizioni aleatorie, utilizziamo la procedura descritta nella Proposizione 5.2.3 finché non sono state colorate $\lceil \sqrt{n} \rceil$ carte e poi passiamo all'algoritmo “Broder accelerato” descritto nella Sezione 5.3.2. Sia τ_n il primo istante in cui ogni carta risulta colorata. Allora τ_n è uno strong stationary time per la catena.

Dimostrazione. Poniamo $m = \lceil \sqrt{n} \rceil$. Durante la prima fase, cioè finché si usa l'algoritmo classico di Broder, la Proposizione 5.2.3 mostra che le carte colorate sono fortemente mescolate tra loro. Rimane quindi da verificare che, una volta passati a Broder accelerato, questa proprietà venga preservata. Sia quindi C_t l'insieme delle carte colorate al tempo t . Supponiamo che valga $|C_t| = k \geq m$, e che le carte in C_t siano fortemente mescolate tra loro.

Supponiamo che non venga colorata nessuna nuova carta, e condizioniamo sul valore della coppia estratta. Si presentano due casi: o vengono scambiate due carte non colorate, oppure viene applicata una permutazione fissata alle carte colorate. In entrambi i casi, le carte in C_t rimangono fortemente mescolate tra loro.

Passiamo al caso in cui viene colorata una nuova carta al tempo $t + 1$. Come nella dimostrazione della Proposizione 5.2.3, condizioniamo sul valore dell'insieme delle carte già colorate, diciamo $C_t = C$, sul fatto che la nuova carta colorata sia $w \notin C$, e sulla disposizione delle carte non appartenenti a $C_{t+1} = C \cup \{w\}$. Dimostriamo che la posizione della carta w è uniformemente distribuita tra le posizioni delle carte in C_{t+1} . La carta w può rimanere nella sua posizione in due modi: se viene scelta la coppia (w, w) , oppure se viene scelta la coppia di carte colorate associata a w nella lista (5.3.1). Ciascuno di questi due eventi ha probabilità $1/n^2$. Quindi la probabilità totale che w venga colorata e rimanga nella sua posizione è $2/n^2$. Analogamente, fissata una carta colorata $c \in C$, la carta w finisce nella posizione occupata da c se viene scelta una delle due coppie ordinate (w, c) oppure (c, w) . Anche in questo caso la probabilità totale è $2/n^2$. Quindi, condizionatamente al fatto che w venga colorata, la sua posizione tra le $k + 1$ posizioni colorate è uniforme. A questo punto si conclude come nella dimostrazione della Proposizione 5.2.3. $\square$

Procedendo come nel Lemma 5.2.6, si ottiene

$$\mathbf{E}[\tau_n] = \frac{5}{4}n \log n + \mathcal{O}(n), \quad \text{Var}(\tau_n) = \mathcal{O}(n^2).$$

Dalla disuguaglianza di Chebyshev segue che, per ogni $\varepsilon > 0$,

$$\mathbf{P}(\tau_n > (1 + \varepsilon)\frac{5}{4}n \log n) \rightarrow 0.$$

Dato che τ_n è uno strong stationary time, per la Proposizione 3.2.6 otteniamo

$$d_n(\lfloor (1 + \varepsilon)\frac{5}{4}n \log n \rfloor) \rightarrow 0.$$

Dimostriamo adesso una stima dal basso per la quantità $d_n(\lfloor (1 - \varepsilon)t_n \rfloor)$, dove $t_n = \frac{1}{2}n \log n$. Poniamo $s_n = \lfloor (1 - \varepsilon)t_n \rfloor$. Cerchiamo un evento A che abbia probabilità tendente a 0 per $n \rightarrow \infty$ sotto la distribuzione uniforme U , e tendente a 1 sotto $P^{s_n}(\text{id}, \cdot)$, la distribuzione di probabilità su S_n ottenuta al tempo s_n partendo dall'identità.

Definiamo la funzione $\text{fix}(\pi) = |\{i \in \{1, 2, \dots, n\} \mid \pi(i) = i\}|$ e sia $A_n = \{\pi \in S_n \mid \text{fix}(\pi) \geq \log n\}$. Dimostriamo che, sotto la distribuzione uniforme U , $\mathbf{E}[\text{fix}] = 1$. Riscriviamo $\text{fix}(\pi)$ come somma di indicatrici:

$$\text{fix}(\pi) = \sum_{i=1}^n \mathbf{1}_{\{\pi(i)=i\}},$$

da cui

$$\mathbf{E}[\text{fix}] = \mathbf{E}\left[\sum_{i=1}^n \mathbf{1}_{\{\pi(i)=i\}}\right] = \sum_{i=1}^n \mathbf{P}(\pi(i) = i) = \sum_{i=1}^n \frac{1}{n} = 1.$$

Dalla disuguaglianza di Markov, segue che

$$U(A_n) \leq \frac{\mathbf{E}[\text{fix}]}{\log n} = \frac{1}{\log n} \xrightarrow{n \rightarrow \infty} 0.$$

Per stimare $P^{s_n}(\text{id}, A_n)$, l'idea è che, se una carta C non è mai stata selezionata, ovvero $C \notin \{L_1, R_1, L_2, R_2, \dots, L_{s_n}, R_{s_n}\}$, allora questa corrisponde a un punto fisso per la permutazione π_{s_n} . Al tempo s_n le carte che sono state scelte sono $2s_n \leq (1 - \varepsilon)n \log n$, quindi si tratta di far vedere che, nel problema del collezionista descritto nel Capitolo 3, la probabilità che almeno $\log n$ tipi non siano stati selezionati dopo $(1 - \varepsilon)n \log n$ estrazioni tende a 1 per $n \rightarrow \infty$.

Poniamo $\ell_n = \lceil \log n \rceil$ e sia $T_{n-\ell_n}$ il primo istante in cui, nel problema del collezionista con n tipi, sono stati visti almeno $n - \ell_n$ tipi diversi.

Procedendo come nella Proposizione 3.2.8 si ottiene

$$\mathbf{E}(T_{n-\ell_n}) = \sum_{k=1}^{n-\ell_n} \frac{n}{n-k+1} = n \sum_{j=\ell_n+1}^n \frac{1}{j} = n \log n - n \log \log n + \mathcal{O}(n),$$

e

$$\text{Var}(T_{n-\ell_n}) \leq n^2 \sum_{j=\ell_n+1}^n \frac{1}{j^2} = \mathcal{O}(n^2).$$

Notiamo che

$$\mathbf{E}(T_{n-\ell_n}) - (1 - \varepsilon)n \log n = \varepsilon n \log n - n \log \log n + \mathcal{O}(n),$$

e per n sufficientemente grande questa quantità è almeno $\frac{\varepsilon}{2}n \log n$. Applicando la disuguaglianza di Chebyshev otteniamo

$$\begin{aligned} \mathbf{P}(T_{n-\ell_n} \leq (1 - \varepsilon)n \log n) &\leq \mathbf{P}\left(|T_{n-\ell_n} - \mathbf{E}(T_{n-\ell_n})| \geq \frac{\varepsilon}{2}n \log n\right) \\ &\leq \frac{\text{Var}(T_{n-\ell_n})}{\left(\frac{\varepsilon}{2}n \log n\right)^2} = \mathcal{O}\left(\frac{1}{\log^2 n}\right) \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

Dunque al tempo s_n ci sono almeno $\log n$ carte che non sono mai state selezionate con probabilità che tende a 1 per $n \rightarrow \infty$, e quindi

$$P^{s_n}(\text{id}, A_n) \xrightarrow{n \rightarrow \infty} 1.$$

Dato che $U(A_n) \rightarrow 0$, otteniamo

$$d_n(s_n) \geq P^{s_n}(\text{id}, A_n) - U(A_n) \xrightarrow{n \rightarrow \infty} 1.$$

5.4 Profilo limite

Le stime ottenute in questo capitolo non costituiscono una dimostrazione completa del cutoff ottimale per le trasposizioni aleatorie. La stima dal basso mostra che prima del tempo $\frac{1}{2}n \log n$ la catena è lontana dall'equilibrio, mentre lo strong stationary time ottenuto combinando Broder e Broder accelerato mostra che la catena è vicina all'equilibrio al tempo $\frac{5}{4}n \log n$. Il risultato esatto, dimostrato originariamente da Diaconis e Shahshahani, afferma che il cutoff avviene al tempo $\frac{1}{2}n \log n$. Oggi è noto un risultato più preciso, ovvero il profilo limite della funzione $d_n(t)$ nella finestra temporale di ordine n attorno a $\frac{1}{2}n \log n$. Nell'articolo [Tey20], viene dimostrato che per ogni $c \in \mathbb{R}$ si ha

$$\lim_{n \rightarrow \infty} d_n \left(\left\lfloor \frac{1}{2}n \log n + cn \right\rfloor \right) = \|\text{Poiss}(1 + e^{-2c}) - \text{Poiss}(1)\|_{\text{TV}},$$

dove $\text{Poiss}(\lambda)$ indica la distribuzione di Poisson di parametro λ .

Più recentemente, Jain e Sawhney [JS24] hanno ottenuto una descrizione diversa di ciò che succede vicino al cutoff. Se τ_{touch} è il primo istante in cui tutte le carte sono state selezionate almeno una volta da una delle due mani e indichiamo con $\mu_{\tau_{\text{touch}}}$ la distribuzione di $\pi_{\tau_{\text{touch}}}$, allora

$$\|\mu_{\tau_{\text{touch}}} - U\|_{\text{TV}} \leq \exp \left(-(\log n)^{1/2+o(1)} \right).$$

Al tempo $\tau_{\text{touch}} - 1$, invece, la distanza in variazione totale è almeno $(1 + o(1))e^{-1}$. Questo mostra che, asintoticamente, il primo istante in cui tutte le carte sono state toccate è sufficiente per mescolare il mazzo in variazione totale, e che questo risultato è ottimale.

Capitolo 6

Trasposizioni adiacenti

6.1 Introduzione al problema

In questo capitolo analizziamo un'altra passeggiata aleatoria sul gruppo simmetrico S_n : la catena delle trasposizioni adiacenti. Abbiamo un mazzo di n carte numerate da 1 a n e, a ogni passo, scegliamo uniformemente una posizione $i \in [n-1]$. Consideriamo quindi le carte nelle posizioni i e $i+1$ e, con probabilità $\frac{1}{2}$, le lasciamo nell'ordine in cui si trovano, mentre con probabilità $\frac{1}{2}$ le scambiamo. Questo corrisponde alla passeggiata aleatoria su S_n con transizioni date da

$$\mu(\sigma) = \begin{cases} \frac{1}{2}, & \text{se } \sigma = \text{id}, \\ \frac{1}{2(n-1)}, & \text{se } \sigma = (i, i+1) \text{ per qualche } i \in [n-1], \\ 0, & \text{altrimenti.} \end{cases}$$

Manterremo la convenzione secondo cui $\pi_t(j)$ indica la carta nella posizione j al tempo t . Nel caso delle trasposizioni aleatorie venivano scelte due carte, mentre in questo caso vengono scelte due posizioni. Dunque se viene scelta la trasposizione $s_i = (i, i+1)$, abbiamo $\pi_{t+1} = \pi_t \circ s_i$. Si tratta quindi di una passeggiata aleatoria a destra, ma ci si può ricondurre alla passeggiata a sinistra considerando le permutazioni inverse, che non modifica le stime di mixing. Trattandosi di una passeggiata aleatoria su un gruppo, la sua distribuzione stazionaria è la distribuzione uniforme.

La differenza principale rispetto alle trasposizioni aleatorie, analizzate nel capitolo precedente, è che le mosse sono locali. Nel caso delle trasposizioni aleatorie una carta può essere scambiata direttamente con qualunque altra carta del mazzo; qui invece una carta può essere scambiata solo con le carte adiacenti. Per questo motivo ci aspettiamo che l'ordine del mixing time sia molto più alto. Vedremo infatti che l'ordine corretto è $n^3 \log n$, invece di $n \log n$.

Questo modello è strettamente collegato anche al *simple exclusion process*, che è un modello di fisica statistica. Fissata una soglia k , si possono interpretare le carte con etichetta minore o uguale a k come particelle e le altre come siti vuoti. Così facendo,

uno scambio tra due posizioni adiacenti corrisponde al salto di una particella verso un sito vicino, quando questo è vuoto. Questo legame è centrale nell'analisi di Lacoïn [Lac16].

Il problema è stato inizialmente affrontato da Aldous [Ald83], che dimostrò una stima superiore di ordine $\mathcal{O}(n^3 \log n)$ e una stima inferiore di ordine $\Omega(n^3)$. Un progresso sostanziale è stato fatto da Wilson [Wil04], riconducendo lo studio delle trasposizioni adiacenti a quello dei cammini sui reticoli: in questo modo ha ottenuto che, asintoticamente, prima del tempo $\frac{1}{\pi^2} n^3 \log n$ la catena è ancora lontana dall'equilibrio, mentre dopo il tempo $\frac{2}{\pi^2} n^3 \log n$ è vicina alla stazionarietà. Wilson ha congetturato inoltre che la costante corretta sia $\frac{1}{\pi^2}$.

La congettura è stata poi dimostrata da Lacoïn [Lac16], che ha mostrato che la catena delle trasposizioni adiacenti presenta cutoff al tempo

$$\frac{1}{\pi^2} n^3 \log n.$$

In questo capitolo inizieremo seguendo la presentazione di [LP17, Sezione 16.1.4], in cui viene costruita un'autofunzione naturale per la catena seguendo una singola carta. Applicando il metodo di Wilson per le stime dal basso otterremo che, prima del tempo $\frac{1}{\pi^2} n^3 \log n$, la catena è ancora lontana dall'equilibrio. Per la stima dall'alto useremo la riduzione ai cammini sui reticoli di Wilson [Wil04]. Li studieremo tramite un'opportuna autofunzione, che deriva da quella ottenuta seguendo una singola carta. Otterremo una stima più debole rispetto a quella dell'articolo originale, ovvero che dopo il tempo $\frac{8}{\pi^2} n^3 \log n$ la catena è vicina alla stazionarietà.

6.2 Stima dal basso

Cominciamo analizzando cosa succede seguendo una singola carta, ad esempio la carta 1. La sequenza $(\pi_t^{-1}(1))$ è una catena di Markov su $[n]$ che evolve nel modo seguente. Quando si trova in $\{2, 3, \dots, n-1\}$ si muove di ± 1 con probabilità $\frac{1}{2(n-1)}$ per ciascuna direzione, mentre quando si trova agli estremi si muove con probabilità $\frac{1}{2(n-1)}$ nella posizione adiacente. Questa è una versione estremamente lazy della catena su $[n]$ che quando si trova in $\{2, 3, \dots, n-1\}$ si muove di ± 1 con probabilità $\frac{1}{2}$ per ciascuna direzione, mentre quando si trova agli estremi resta ferma con probabilità $\frac{1}{2}$ e si muove con probabilità $\frac{1}{2}$ nella posizione adiacente. Si tratta di una catena ben nota, di cui si possono calcolare autovalori e autofunzione in maniera simile all'Esempio 3.3.10, ottenendo che la funzione

$$\varphi(k) = \cos\left(\frac{(2k-1)\pi}{2n}\right)$$

è un'autofunzione di autovalore $\cos\left(\frac{\pi}{n}\right)$. Una dimostrazione di questo fatto si trova in [LP17, Sezione 12.3.2]. Quindi la funzione φ è un'autofunzione della catena che segue una singola carta di autovalore

$$(6.2.1) \quad \lambda = \frac{1}{n-1} \cos\left(\frac{\pi}{n}\right) + \frac{n-2}{n-1} = 1 - \frac{\pi^2}{2n^3} + O(n^{-4}).$$

Dal Lemma 3.3.9 segue che, per ogni carta i , la funzione $\pi \mapsto \varphi(\pi^{-1}(i))$ è un'autofunzione della catena delle trasposizioni adiacenti con autovalore λ . La funzione usata da Levin, Peres e Wilmer [LP17, Sezione 16.1.4], che indicheremo con Φ , è la combinazione lineare

$$(6.2.2) \quad \begin{aligned} \Phi(\pi) &= \sum_{a=1}^n \varphi(a) \varphi(\pi^{-1}(a)) \\ &= \sum_{j=1}^n \varphi(j) \varphi(\pi(j)). \end{aligned}$$

Per applicare il Teorema 3.3.15, dobbiamo scegliere uno stato iniziale e stimare la variazione della funzione Φ in un passo della catena.

Proposizione 6.2.1 (Stima inferiore per le trasposizioni adiacenti). Sia $d_n(t)$ la distanza dalla stazionarietà delle trasposizioni adiacenti su S_n . Per ogni $\varepsilon \in (0, 1)$,

$$\lim_{n \rightarrow \infty} d_n \left(\lfloor (1 - \varepsilon) \frac{1}{\pi^2} n^3 \log n \rfloor \right) = 1.$$

Dimostrazione. Appliciamo il Teorema 3.3.15 alla funzione Φ , partendo dall'identità. Consideriamo l'effetto di una trasposizione $(k-1 \ k)$ sulla funzione Φ . Dalla definizione (6.2.2), per ogni $\pi \in S_n$, abbiamo

$$\begin{aligned} |\Phi(\pi \circ (k-1 \ k)) - \Phi(\pi)| &= |\varphi(k) \varphi(\pi(k-1)) + \varphi(k-1) \varphi(\pi(k)) \\ &\quad - \varphi(k-1) \varphi(\pi(k-1)) - \varphi(k) \varphi(\pi(k))| \\ &= |(\varphi(k) - \varphi(k-1))(\varphi(\pi(k-1)) - \varphi(\pi(k)))| \\ &\leq \frac{\pi}{n} 2 = \frac{2\pi}{n}, \end{aligned}$$

dove nell'ultimo passaggio abbiamo usato che $|\varphi'| \leq \pi/n$ e $|\varphi| \leq 1$. Dunque

$$(6.2.3) \quad \mathbf{E}_\pi \left[|\Phi(X_1) - \Phi(\pi)|^2 \right] \leq \frac{4\pi^2}{n^2}.$$

Ricordiamo la stima del Teorema 3.3.15:

$$(6.2.4) \quad t_{\text{mix}}(\varepsilon) \geq \frac{1}{2 \log(1/\lambda)} \left[\log \left(\frac{(1 - \lambda) \Phi(x)^2}{2R} \right) + \log \left(\frac{1 - \varepsilon}{\varepsilon} \right) \right],$$

dove l'Equazione (6.2.3) mostra che possiamo prendere $R = 4\pi^2/n^2$. Resta da calcolare la quantità $\Phi(\text{id})$. Dalla definizione (6.2.2),

$$\Phi(\text{id}) = \sum_{j=1}^n \varphi(j)^2 = \sum_{j=1}^n \cos^2 \left(\frac{(2j-1)\pi}{2n} \right).$$

Usando $\cos^2 x = \frac{1 + \cos(2x)}{2}$ otteniamo

$$\Phi(\text{id}) = \frac{n}{2} + \frac{1}{2} \sum_{j=1}^n \cos \left(\frac{(2j-1)\pi}{n} \right).$$

L'ultima somma è nulla, perché è la parte reale di

$$\sum_{j=1}^n e^{i(2j-1)\pi/n} = e^{i\pi/n} \sum_{j=0}^{n-1} e^{2\pi i j/n} = 0.$$

Quindi $\Phi(\text{id}) = \frac{n}{2}$. Sostituendo nell'Equazione (6.2.4) otteniamo, per ogni $\delta \in (0, 1)$,

$$t_{\text{mix}}(\delta) \geq \frac{n^3 \log n}{\pi^2} + (C_\delta + o(1))n^3.$$

Quindi per ogni $\delta \in (0, 1)$ si ha

$$\liminf_{n \rightarrow \infty} d_n \left(\left\lfloor (1 - \varepsilon) \frac{1}{\pi^2} n^3 \log n \right\rfloor \right) \geq \delta.$$

Facendo tendere δ a 1 si ottiene la tesi. $\square$

6.3 Cammini sui reticoli e autofunzione

Vediamo come Wilson riconduce lo studio delle trasposizioni adiacenti a quello dei cammini sui reticoli, descritti nell'Esempio 3.1.6.

Data una permutazione $\pi \in S_n$, per ogni soglia k registriamo quali posizioni sono occupate dalle carte minori o uguali a k .

Definizione 6.3.1 (Funzioni soglia). Per $k \in \{0, \dots, n\}$ definiamo la k -esima *funzione soglia* di π come la parola $r_k(\pi) \in \{0, 1\}^n$ data da

$$(r_k(\pi))_j = \begin{cases} 1, & \text{se } \pi(j) \leq k, \\ 0, & \text{se } \pi(j) > k. \end{cases}$$

La parola $r_k(\pi)$ contiene esattamente k simboli uguali a 1 e $n - k$ simboli uguali a 0, e può quindi essere identificata con un cammino di $\mathcal{R}_{n-k, k}$.

Le funzioni soglia determinano in modo univoco la permutazione: infatti vale

$$\pi(j) = n + 1 - \sum_{k=1}^n (r_k(\pi))_j.$$

Costruiamo adesso il grand coupling sulle permutazioni, usando la stessa sequenza di aggiornamenti casuali per tutti i possibili stati iniziali. A ogni passo scegliamo una posizione $i \in [n - 1]$ e lanciamo una moneta equilibrata; poi ordiniamo le due carte nelle posizioni i e $i + 1$ in modo crescente o decrescente a seconda dell'esito. Fissata una soglia k , questi stessi aggiornamenti casuali inducono sulla catena $(r_k(\pi_t))$ le seguenti probabilità di transizione: si sceglie una posizione i e si ordinano in modo crescente o decrescente i due simboli in posizioni i e $i + 1$. Quindi la proiezione $(r_k(\pi_t))$ coincide con

la catena sui cammini $\mathcal{R}_{n-k,k}$ dell'Esempio 3.1.6, costruita con gli stessi aggiornamenti casuali.

Dato che le funzioni soglia determinano la permutazione, lo studio della coalescenza delle permutazioni si riconduce allo studio della coalescenza delle soglie. Il vantaggio è che, per ogni soglia k , il grand coupling è monotono, e quindi possiamo limitarci a studiare il tempo di coalescenza dei cammini estremali in $\mathcal{R}_{n-k,k}$. Per concludere, stimeremo il tempo di coalescenza del grand coupling sulle permutazioni con una stima dell'unione sulle $n-1$ soglie.

Per ottenere questa stima costruiamo un'autofunzione Ψ per le catene sui cammini, che deriva dall'autofunzione Φ introdotta nella sezione precedente.

Analizziamo il contributo di ogni soglia nella funzione

$$\Phi(\pi) = \sum_{j=1}^n \varphi(j) \varphi(\pi(j)), \quad \text{dove } \varphi(j) = \cos\left(\frac{(2j-1)\pi}{2n}\right).$$

Per ogni $m \in [n]$ vale la decomposizione telescopica

$$\varphi(m) = \varphi(n) + \sum_{k=1}^{n-1} (\varphi(k) - \varphi(k+1)) \mathbf{1}_{\{m \leq k\}}.$$

Applicandola a $m = \pi(j)$ otteniamo

$$\varphi(\pi(j)) = \varphi(n) + \sum_{k=1}^{n-1} (\varphi(k) - \varphi(k+1)) (r_k(\pi))_j.$$

Moltiplicando per $\varphi(j)$ e sommando su j otteniamo

$$\Phi(\pi) = \varphi(n) \sum_{j=1}^n \varphi(j) + \sum_{j=1}^n \varphi(j) \sum_{k=1}^{n-1} (\varphi(k) - \varphi(k+1)) (r_k(\pi))_j.$$

Il primo termine è nullo, perché $\sum_{j=1}^n \varphi(j) = 0$. Per il secondo termine, scambiando l'ordine delle somme otteniamo

$$\sum_{k=1}^{n-1} (\varphi(k) - \varphi(k+1)) \sum_{j=1}^n (r_k(\pi))_j \varphi(j).$$

Questo motiva la seguente definizione: per un cammino $r \in \mathcal{R}_{n-k,k}$ poniamo

$$\Psi(r) = \sum_{j=1}^n r_j \varphi(j).$$

La decomposizione precedente diventa

$$\Phi(\pi) = \sum_{k=1}^{n-1} (\varphi(k) - \varphi(k+1)) \Psi(r_k(\pi)).$$

Fissata una soglia k , mostriamo che Ψ è un'autofunzione per la catena sui cammini $\mathcal{R}_{n-k,k}$. Per ogni permutazione π si ha

$$\Psi(r_k(\pi)) = \sum_{j=1}^n (r_k(\pi))_j \varphi(j) = \sum_{j: \pi(j) \leq k} \varphi(j) = \sum_{i=1}^k \varphi(\pi^{-1}(i)).$$

Nella sezione precedente abbiamo visto che, per ogni i , la funzione $\pi \mapsto \varphi(\pi^{-1}(i))$ è un'autofunzione della catena delle trasposizioni adiacenti con autovalore λ , quindi anche la funzione $\Psi(r_k(\pi))$ lo è. Inoltre questa funzione dipende da π solo attraverso la proiezione $r_k(\pi)$, e la catena $(r_k(\pi_t))_{t \geq 0}$ è la catena sui cammini $\mathcal{R}_{n-k,k}$. Applicando il Lemma 3.3.9, otteniamo quindi che Ψ è un'autofunzione della catena sui cammini $\mathcal{R}_{n-k,k}$ con autovalore λ .

Osserviamo infine che Ψ può essere interpretata anche in termini delle funzioni altezza, date da $H_j(r) = \sum_{i \leq j} r_i$. Poniamo $H_0(r) = 0$. Sostituendo $r_j = H_j(r) - H_{j-1}(r)$ nell'identità

$$\sum_{j=1}^n a_j (b_j - b_{j-1}) = \sum_{j=1}^{n-1} b_j (a_j - a_{j+1}) + b_n a_n, \quad b_0 = 0,$$

detta sommazione per parti di Abel, si ottiene

$$(6.3.1) \quad \Psi(r) = \sum_{j=1}^{n-1} H_j(r) (\varphi(j) - \varphi(j+1)) + H_n(r) \varphi(n).$$

6.4 Stima dall'alto

Indichiamo con $\tau_{n-k,k}$ il tempo di coalescenza dei due cammini estremali $r^{\min} \preceq r^{\max}$ del grand coupling monotono su $\mathcal{R}_{n-k,k}$: $r^{\max}$ è il cammino massimo, in cui i k passi verso l'alto sono tutti all'inizio, e $r^{\min}$ è il cammino minimo, in cui sono tutti alla fine.

Seguiamo l'argomento di Wilson [Wil04, Sezione 3.2] per stimare dall'alto il tempo di coalescenza dei cammini estremali. L'idea è che i due cammini coincidono se e solo se $D_t := \Psi(r_t^{\max}) - \Psi(r_t^{\min}) = 0$, e il valore atteso di questa quantità decresce come λ^t . Inoltre se i due cammini non coincidono, D_t è maggiore o uguale di una certa soglia δ . Quindi dopo un numero sufficiente di passi, il fatto che il valore atteso sia molto vicino a 0 implica che $\Psi(r_t^{\max}) - \Psi(r_t^{\min}) = 0$ con alta probabilità.

Proposizione 6.4.1 (Coalescenza dei cammini estremali). Per la catena sui cammini $\mathcal{R}_{n-k,k}$, per ogni $t \geq 0$ vale

$$\mathbf{P}(\tau_{n-k,k} > t) \leq \frac{n^3}{2} \lambda^t, \quad \text{dove } \lambda = 1 - \frac{1 - \cos(\pi/n)}{n-1}.$$

Dimostrazione. Poniamo $D_t = \Psi(r_t^{\max}) - \Psi(r_t^{\min})$. Per mostrare che $D_t = 0$ se e solo se $r_t^{\max} = r_t^{\min}$, mostriamo che la funzione Ψ è strettamente monotona rispetto

all'ordinamento $\preceq$, usando l'Equazione (6.3.1). Dato che ogni cammino di $\mathcal{R}_{n-k,k}$ ha $H_n = k$, otteniamo che per ogni $r, r' \in \mathcal{R}_{n-k,k}$ vale

$$(6.4.1) \quad \Psi(r) - \Psi(r') = \sum_{j=1}^{n-1} (H_j(r) - H_j(r')) (\varphi(j) - \varphi(j+1)).$$

I coefficienti

$$\varphi(j) - \varphi(j+1) = 2 \sin\left(\frac{\pi}{2n}\right) \sin\left(\frac{\pi j}{n}\right)$$

sono positivi. Da questo segue immediatamente che se $r' \preceq r$, allora $\Psi(r) - \Psi(r') \geq 0$, e l'uguaglianza vale soltanto quando $r = r'$. Quindi in particolare vale

$$D_t = 0 \iff r_t^{\max} = r_t^{\min}.$$

Mostriamo adesso che, se la quantità D_t è strettamente positiva, allora non può essere minore di una certa soglia. Quando $r_t^{\max} \neq r_t^{\min}$, esiste almeno un j con $H_j(r_t^{\max}) - H_j(r_t^{\min}) \geq 1$. Dall'Equazione (6.4.1) segue che

$$D_t \geq \min_{1 \leq j \leq n-1} (\varphi(j) - \varphi(j+1)) =: \delta,$$

e quindi otteniamo

$$\{\tau_{n-k,k} > t\} = \{D_t \geq \delta\}.$$

Stimiamo la probabilità di questo evento tramite la disuguaglianza di Markov, sfruttando il fatto che, essendo Ψ un'autofunzione, vale

$$\begin{aligned} \mathbf{E}[D_t] &= \mathbf{E}[\Psi(r_t^{\max})] - \mathbf{E}[\Psi(r_t^{\min})] \\ &= \lambda^t (\Psi(r_0^{\max}) - \Psi(r_0^{\min})) \\ &= \lambda^t D_0. \end{aligned}$$

Dunque

$$\mathbf{P}(\tau_{n-k,k} > t) = \mathbf{P}(D_t \geq \delta) \leq \frac{\mathbf{E}[D_t]}{\delta} = \frac{\lambda^t D_0}{\delta}.$$

Resta da stimare il rapporto D_0/δ . Dato che $|\Psi(r)| \leq n$ per ogni cammino r , si ha $D_0 \leq 2n$. Inoltre, il minimo di $\sin(\pi j/n)$, per $1 \leq j \leq n-1$, è raggiunto per $j = 1$ oppure per $j = n-1$, e quindi

$$\delta = 2 \sin\left(\frac{\pi}{2n}\right) \sin\left(\frac{\pi}{n}\right).$$

Usando la disuguaglianza $\sin x \geq \frac{2}{\pi}x$, valida per $x \in [0, \pi/2]$, si ottiene

$$\delta \geq 2 \cdot \frac{2}{\pi} \frac{\pi}{2n} \cdot \frac{2}{\pi} \frac{\pi}{n} = \frac{4}{n^2},$$

e quindi $D_0/\delta \leq n^3/2$. Da questo segue che $\mathbf{P}(\tau_{n-k,k} > t) \leq \frac{n^3}{2} \lambda^t$. □

Proposizione 6.4.2 (Stima superiore per le trasposizioni adiacenti). Sia $d_n(t)$ la distanza dalla stazionarietà delle trasposizioni adiacenti su S_n . Per ogni $\varepsilon > 0$,

$$\lim_{n \rightarrow \infty} d_n \left(\left\lceil (1 + \varepsilon) \frac{8}{\pi^2} n^3 \log n \right\rceil \right) = 0.$$

Dimostrazione. Per la disuguaglianza di coupling (Corollario 3.1.4) $d_n(t)$ è maggiorata dalla probabilità che il grand coupling sulle permutazioni non sia ancora coalescente al tempo t . Questo accade solo se almeno una delle $n-1$ proiezioni $\mathcal{R}_{n-k,k}$ ($1 \leq k \leq n-1$) non è coalescente. Stimando la probabilità dell'unione con la somma delle probabilità e usando la Proposizione 6.4.1 otteniamo

$$d_n(t) \leq \sum_{k=1}^{n-1} \mathbf{P}(\tau_{n-k,k} > t) \leq (n-1) \frac{n^3}{2} \lambda^t \leq \frac{n^4}{2} \lambda^t.$$

Poniamo

$$t_n = \left\lceil (1 + \varepsilon) \frac{8}{\pi^2} n^3 \log n \right\rceil.$$

Dato che

$$1 - \lambda = \frac{1 - \cos(\pi/n)}{n-1} = \frac{\pi^2}{2n^3} (1 + o(1)),$$

e $1 - x \leq e^{-x}$, si ha

$$\lambda^{t_n} \leq \exp(-(1 - \lambda)t_n) = \exp(-(4 + 4\varepsilon + o(1)) \log n) = n^{-4(1+\varepsilon)+o(1)}.$$

Quindi

$$d_n(t_n) \leq \frac{n^4}{2} \lambda^{t_n} \leq \frac{1}{2} n^{-4\varepsilon+o(1)} \xrightarrow{n \rightarrow \infty} 0,$$

che è la tesi. □

Le Proposizioni 6.2.1 e 6.4.2 mostrano che un eventuale tempo di cutoff è compreso tra $\frac{1}{\pi^2} n^3 \log n$ e $\frac{8}{\pi^2} n^3 \log n$. Come ricordato all'inizio del capitolo, Lacoïn ha dimostrato in [Lac16] che il fenomeno del cutoff si verifica e che la costante corretta è $\frac{1}{\pi^2}$.

Bibliografia

- [AD86] David Aldous and Persi Diaconis, *Shuffling cards and stopping times*, The American Mathematical Monthly **93** (1986), no. 5, 333–348.
- [AD87] David Aldous and Persi Diaconis, *Strong uniform times and finite random walks*, Advances in Applied Mathematics **8** (1987), no. 1, 69–97.
- [Ald83] David Aldous, *Random walks on finite groups and rapidly mixing markov chains*, Seminar on Probability, XVII, Lecture Notes in Mathematics, vol. 986, Springer, Berlin, 1983, pp. 243–297.
- [Bro85] Andrei Broder, *Strong uniform times for random transpositions*, 1985, Manoscritto non pubblicato.
- [Dia88] Persi Diaconis, *Group representations in probability and statistics*, Lecture Notes–Monograph Series, vol. 11, Institute of Mathematical Statistics, Hayward, CA, 1988.
- [DS81] Persi Diaconis and Mehrdad Shahshahani, *Generating a random permutation with random transpositions*, Zeitschrift für Wahrscheinlichkeitstheorie und Verwandte Gebiete **57** (1981), no. 2, 159–179.
- [JS24] Vishesh Jain and Mehtaab Sawhney, *Hitting time mixing for the random transposition walk*, 2024, arXiv preprint arXiv:2410.23944.
- [Lac16] Hubert Lacoin, *Mixing time and cutoff for the adjacent transposition shuffle and the simple exclusion*, The Annals of Probability **44** (2016), no. 2, 1426–1487.
- [LP17] David A. Levin and Yuval Peres, *Markov chains and mixing times*, second ed., American Mathematical Society, 2017, With contributions by Elizabeth L. Wilmer.
- [Mat88] Peter Matthews, *A strong uniform time for random transpositions*, Journal of Theoretical Probability **1** (1988), no. 4, 411–423.
- [Tey20] Lucas Teyssier, *Limit profile for random transpositions*, The Annals of Probability **48** (2020), no. 5, 2323–2343.

- [Whi17] Graham White, *Combinatorial methods in markov chain mixing*, Ph.D. thesis, Stanford University, 2017.
- [Wil91] David Williams, *Probability with martingales*, Cambridge Mathematical Textbooks, Cambridge University Press, Cambridge, 1991.
- [Wil04] David Bruce Wilson, *Mixing times of lozenge tiling and card shuffling markov chains*, The Annals of Applied Probability **14** (2004), no. 1, 274–325.